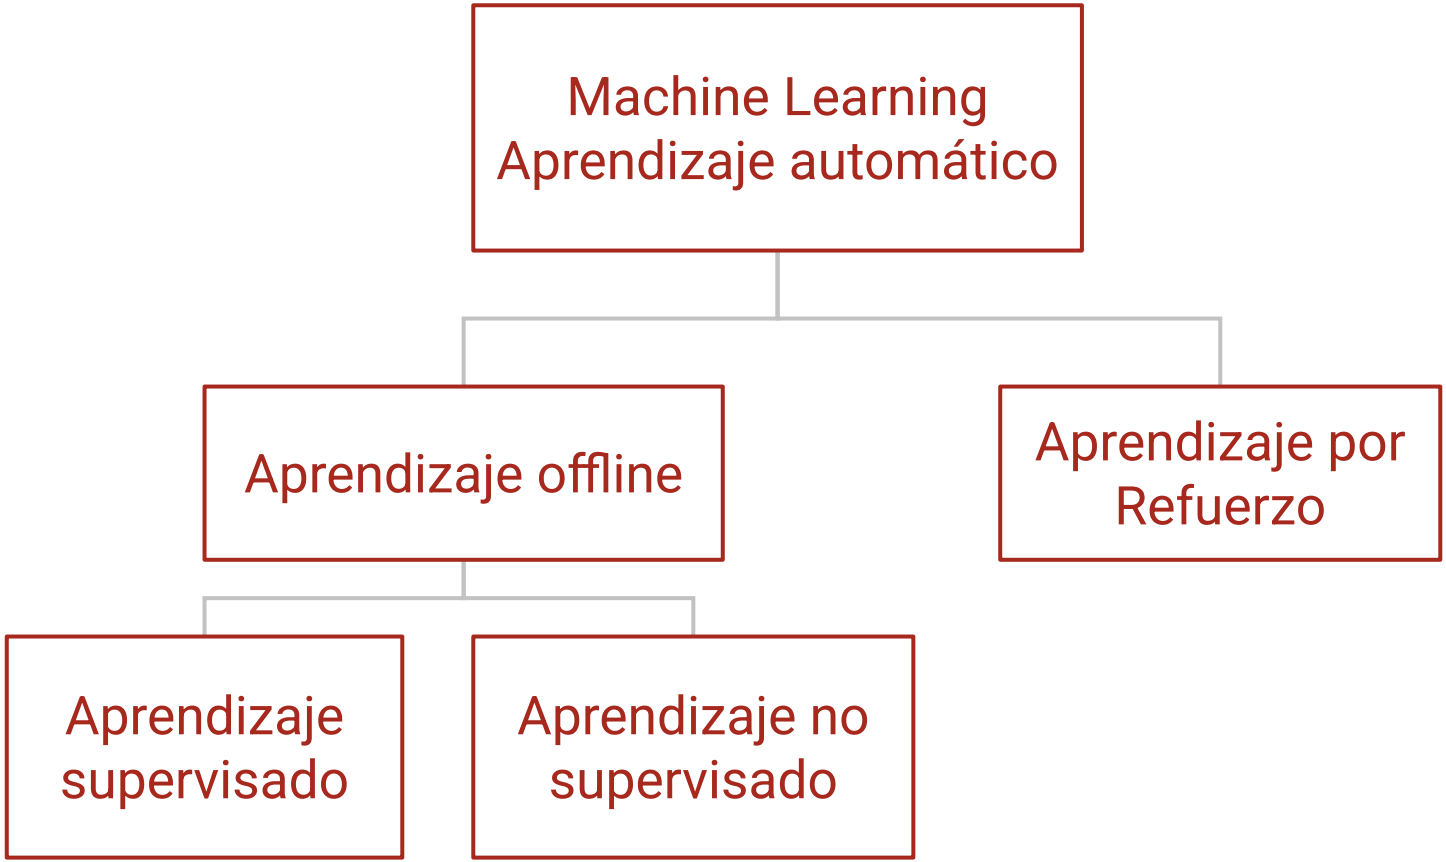
Aprendizaje no Supervisado

Muchas veces las clasificaciones son necesarias para entender qué tipo de problema uno tiene


Machine Learning
Aprendizaje automático
Aprendizaje offline
Aprendizaje por Refuerzo
Aprendizaje supervisado
Aprendizaje no supervisado

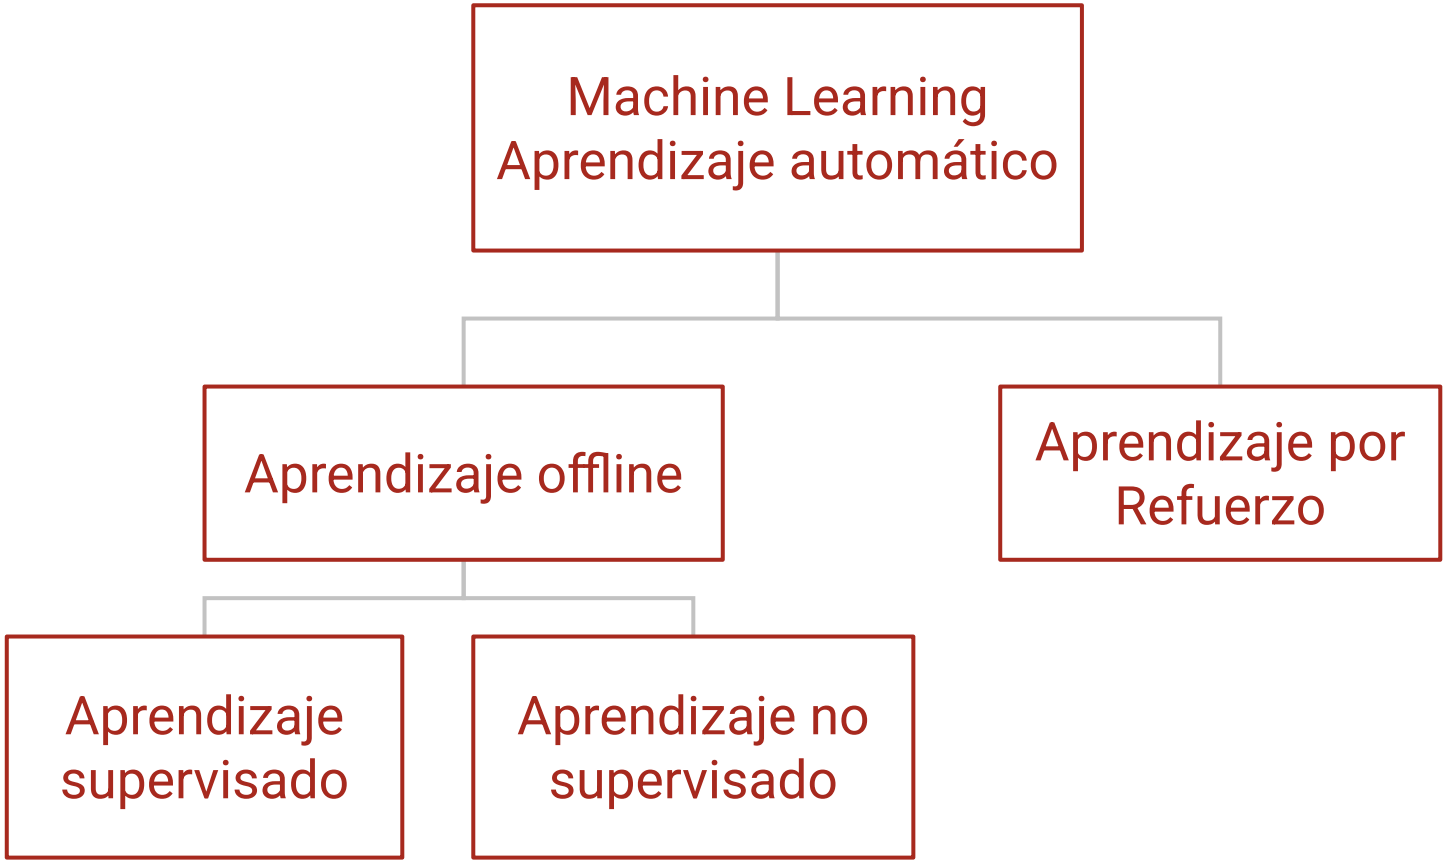
Componente de Machine Learning

- Datos
- Modelo
- Función objetivo
- Algoritmos de optimización

Componente de Machine Learning

Esto suele ser la diferencia entre paradigmas

- **Datos**
- Modelo
- Función objetivo
- Algoritmos de optimización


Machine Learning
Aprendizaje automático
Aprendizaje offline
Aprendizaje por Refuerzo
Aprendizaje supervisado
Aprendizaje no supervisado

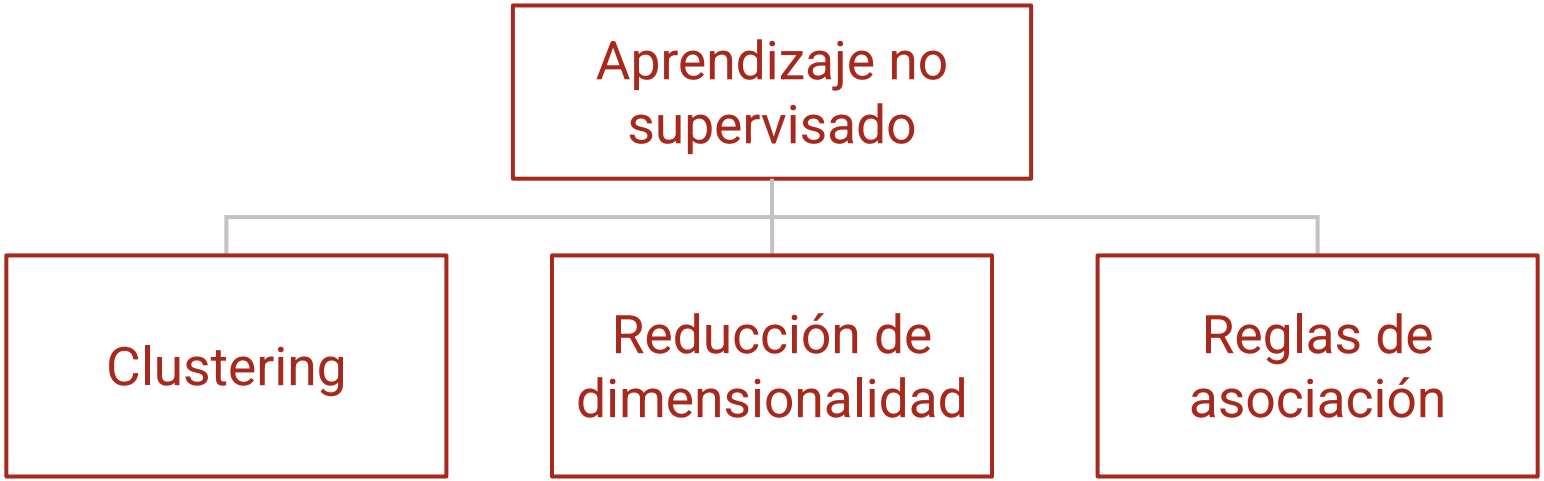
Componente de Machine Learning

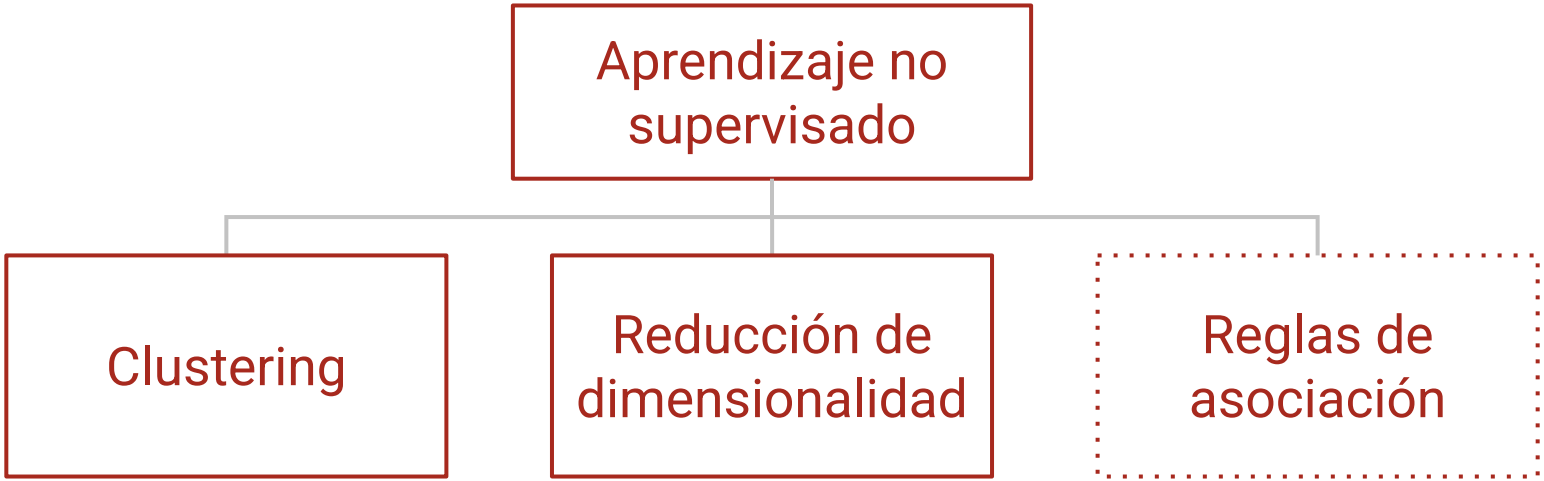
Ejemplos: Árboles de decisión, K-NN

- Datos
- Modelo
- Función objetivo
- Algoritmos de optimización

Árboles de decisión, K-NN son ejemplos de aprendizaje supervisado

Aprendizaje no supervisado


Aprendizaje no supervisado
Clustering
Reducción de dimensionalidad
Reglas de asociación


Aprendizaje no supervisado
Clustering
Reducción de dimensionalidad
Reglas de asociación

Clustering

Una idea que podemos tener es querer saber cómo agrupar nuestros ejemplos a partir de la similitud entre las características o features de nuestros individuos.

Minimizar desemejanza

- variabilidad: varianza de la distancia dentro de un cluster
- desemejanza: suma de las variabilidades por cada cluster

Minimizar desemejanza

Preguntas

- ¿Cómo aseguramos que la disimilitud sea 0?
- ¿Por qué no dividimos la variabilidad por el número de elementos en el cluster para usar la varianza?
- ¿Que distancia usamos?

Hierarchical clustering

Modelo de vacas esféricas.

Lo que intentamos hacer es agrupar a los clusters desde N clusters hasta 1 cluster. Para ello empezamos con N clusters (coincidentes con los individuos o ejemplos) y luego agrupamos los clusters por similitud

Medidas de similitud

Linkage Metrics

Single Linkage:

La distancia entre dos clusters es la menor distancia entre dos elementos de ese cluster

Complete Linkage:

La distancia entre dos clusters es la mayor distancia entre dos elementos de ese cluster

Average Linkage:

La distancia entre dos clusters es el promedio distancia entre dos elementos de ese cluster

	A	B	C	D
A	0	10	14	18
B		0	17	19
C			0	15
D				0

	A	B	C	D
A	0	10	14	18
B		0	17	19
C			0	15
D				0

Usando single linkage

4 clusters {A}, {B}, {C}, {D}

3 clusters {A, B}, {C}, {D}

2 clusters {A, B, C}, {D}

1 cluster {A, B, C, D}

	A	B	C	D
A	0	10	14	18
B		0	17	19
C			0	15
D				0

Usando single linkage

4 clusters {A}, {B}, {C}, {D}

3 clusters {A, B}, {C}, {D}

2 clusters {A, B, C}, {D}

1 cluster {A, B, C, D}

Usando complete linkage

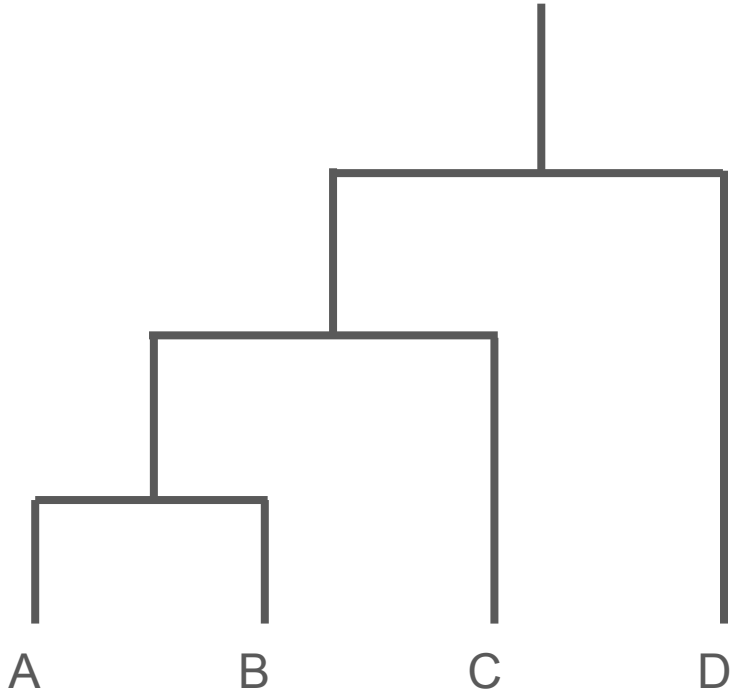
4 clusters {A}, {B}, {C}, {D}

3 clusters {A, B}, {C}, {D}

2 clusters {A, B}, {C, D}

1 cluster {A, B, C, D}

Dendrogramas



Usando single linkage

4 clusters {A}, {B}, {C}, {D}

3 clusters {A, B}, {C}, {D}

2 clusters {A, B, C}, {D}

1 cluster {A, B, C, D}

Ejercicio: hacer el dendrograma

Usando complete linkage

4 clusters {A}, {B}, {C}, {D}

3 clusters {A, B}, {C}, {D}

2 clusters {A, B}, {C, D}

1 cluster {A, B, C, D}

Hierarchical clustering

Modelo de vacas esféricas.

- Determinista
- Greedy
- Complejidad $O(n^3)$
  - $O(n^2)$ si usamos single linkage

K-means

```
initialize k centroids randomly
while (true)
        for x in data:
                assign closest centroid to x // generate clusters
                // the closest x's are the new cluster
        calculate new centroids averaging x's
        if clusters did not change from last iteration, break
return centroids
```

K-means

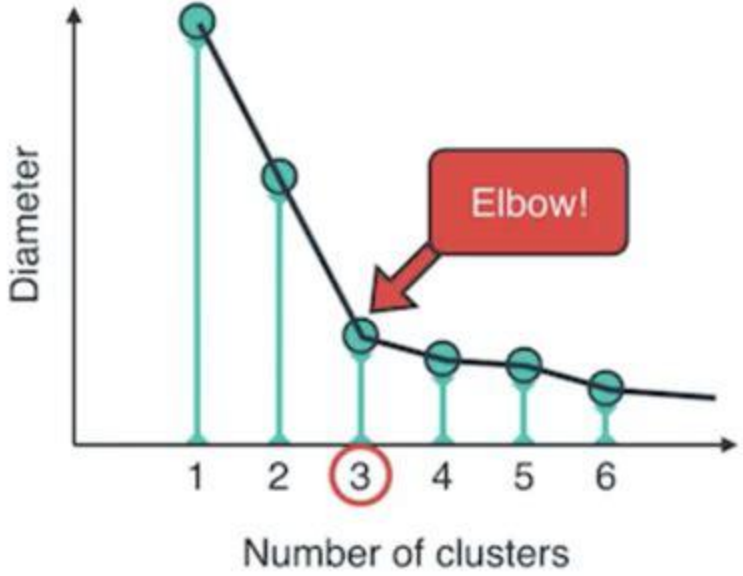
- No determinista
- Greedy
  - promedios de varias ejecuciones
- Complejidad O(nkif)
  - n: cantidad de datos
  - f: número de características
  - i: número de iteraciones

K-means

¿Qué pasa si no conocemos k?

- Hacemos Hierarchical en un grupo reducido y elegimos k
- Método del hombro (elbow method)

Elbow method

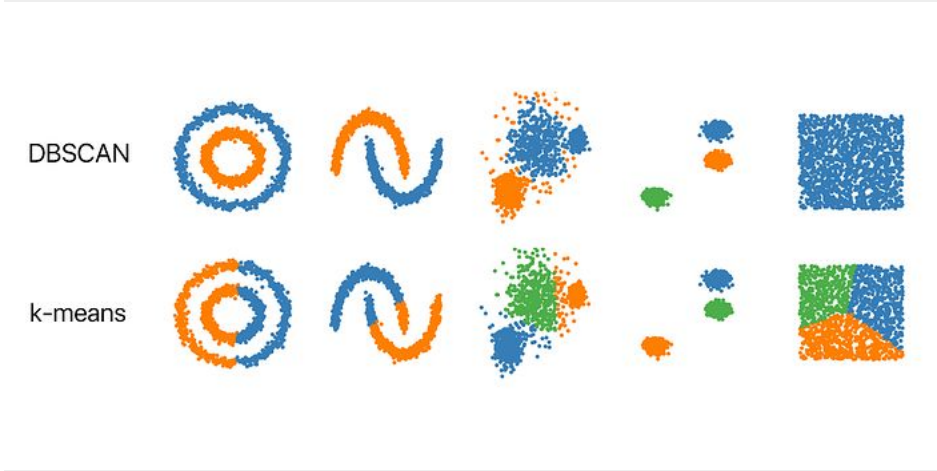


DBSCAN

Density-based spatial clustering of applications with noise

DBSCAN

Density-based spatial clustering of applications with noise



```
for i in data:
        count neighbors around i // the radius is a hyperparameter eps
        if count > N set i as core_point // N is a hyperparameter

clusters = {}
while(core_point is not empty):
        pick a random point j in core_point
        add j to cluster
        neighbors = neighbors(j,core_point)
        while(neighbors is not empy ):
                add k to cluster
                add neighbors(k,core_point) to neighbors if not in cluster
                remove k from neighbors
        add non_core_points close to cluster to cluster
        add cluster to clusters
        remove cluster from core_point
// non-cluster points are noise
```

```
for i in data:
        count neighbors around i // the radius is a hyperparameter eps
        if count > N set i as core_point // N is a hyperparameter

clusters = {}
while(core_point is not empty):
        pick a random point j in core_point
        add j to cluster
        neighbors = neighbors(j,core_point)
        while(neighbors is not empy ):
                add k to cluster
                add neighbors(k,core_point) to neighbors if not in cluster
                remove k from neighbors
        add non_core_points close to cluster to cluster
        add cluster to clusters
        remove cluster from core_point
// non-cluster points are noise
```

Hay un montón de otros algoritmos de clustering

HDBSCAN

Recomendación si quieren explorar más

https://www.youtube.com/watch?v=dGsxd67IFiU

Métricas

Métricas

¿Cómo evaluamos la calidad de clusters si los algoritmos de clusterización detectan clusters en muestras aleatorias?

Métricas

Métricas internas
(miramos solo los datos que tenemos)

Correlación entre matriz similaridad y matriz de incidencia.

- nos indica que tan bien nuestros clusters (I) representan la similitud entre nuestros datos (S)
- I_{ij} = 1 si i y j pertenecen al mismo cluster, sino 0
- la similaridad es una cantidad que es 1 si los ejemplos son iguales y 0 si no tienen nada en común
  - D_{ij} = distancia(i,j),S_{ij} = 1 - D_{ij}/max(D_{ij})
  - similitud coseno
  - correlación conectada (normalizada por desviaciones estándar)

Métricas

Métricas internas
(miramos solo los datos que tenemos)

Cohesión y separación

$$\sum_i \sum_{\mathbf{x} \in C_i} (\mathbf{x} - \mathbf{m}_i)^2 = \sum_i \frac{1}{2|C_i|} \sum_{\mathbf{x},\mathbf{y} \in C_i} (\mathbf{x} - \mathbf{y})^2$$

$$\mathrm{BSS} = \sum_i |C_i| (\mathbf{m} - \mathbf{m}_i)^2$$

Valores relacionados entre ellos, minimizar uno maximina el otro.

Métricas

Métricas internas
(miramos solo los datos que tenemos)

Coeficiente de Silhouette

- a(i) = Distancia promedio de i a los elementos restante de los clusters
- b(i) = Distancia promedio de i a los elementos de otro cluster, elegido de tal modo que minimiza b(i)
- s(i) = [b(i) - a(i)] / max(a(i), b(i))
- SC = promedio de s(i)

Indica que tan bien está representado i dentro del cluster. Mientras más cerca de 1 mejor

Metricas

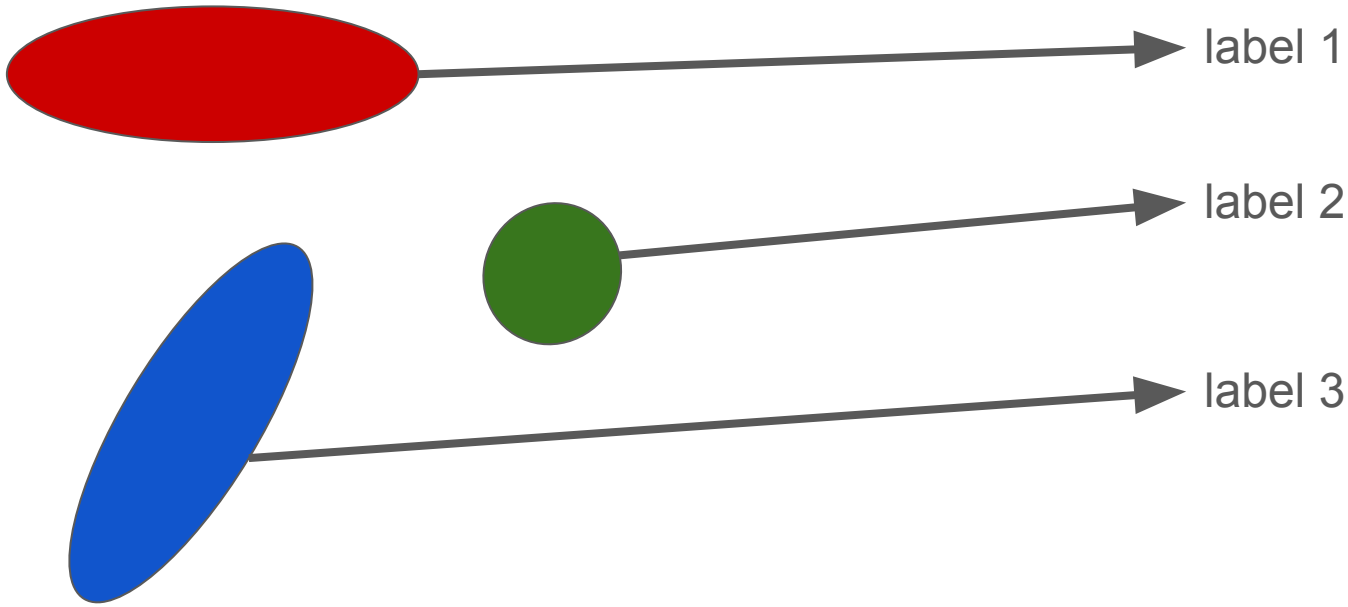
Métricas internas
(miramos solo los datos que tenemos)

Desemejanza

- variabilidad: varianza de la distancia dentro de un cluster
- desemejanza: suma de las variabilidades por cada cluster

Metricas

Métricas externas


label 1
label 2
label 3

Metricas

Métricas externas

- Entropia:

  H(c) = Suma sobre etiquetas i de $-p_i(c) \log(p_i(c))$

  H = Suma sobre clusters c de $H(c) * q_c$

- Pureza:

$$\frac{1}{N} \sum_{m \in M} \max_{d \in D} |m \cap d|$$

Nota: Normalizar las características siempre es una buena idea para lograr buenos clusters

Reducción de dimensionalidad


ABANDON ALL HOPE
YE WHO ENTER HERE

Tenemos nuestros datos representados en una matriz. Cada fila es un dato, cada columna muestreo sobre la variable o característica.

0.0	11.98	8.21	9.04	9.3	11.49	85.41	7.25
0.1	15.09	11.24	8.89	9.39	16.55	70.48	7.04
0.0	11.51	6.86	8.94	9.31	10.82	81.9	7.52
0.1	12.39	8.2	8.8	8.89	12.12	77.09	6.84
0.0	11.78	6.31	9.08	9.8	12.67	79.58	7.24
0.1	13.12	9.11	8.89	9.39	12.78	79.96	6.89
0.0	11.19	7.79	8.35	9.28	10.56	93.43	7.01
0.1	11.54	7.31	8.57	8.89	10.24	61.59	6.81
0.0	11.19	6.27	8.8	9.31	10.75	76.47	7.33
0.1	10.59	5.21	8.7	8.88	9.8	57.68	6.78
0.0	11.33	6.39	8.82	10.5	11.43	92.66	7.31
0.1	10.75	5.66	8.77	8.87	9.88	59.41	6.79
0.0	106.04	46.57	64.07	110.95	132.63	504.97	43.91
0.1	113.37	53.19	65.44	114.44	139.54	505.85	44.6
0.0	99.18	41.68	62.97	100.78	124.49	516.13	45.36
0.1	101.6	50.97	58.93	98.26	128.96	689.13	43.91

0.0	11.98	8.21	9.04	9.3	11.49	85.41	7.25
0.1	15.09	11.24	8.89	9.39	16.55	70.48	7.04
0.0	11.51	6.86	8.94	9.31	10.82	81.9	7.52
0.1	12.39	8.2	8.8	8.89	12.12	77.09	6.84
0.0	11.78	6.31	9.08	9.8	12.67	79.58	7.24
0.1	13.12	9.11	8.89	9.39	12.78	79.96	6.89
0.0	11.19	7.79	8.35	9.28	10.56	93.43	7.01
0.1	11.54	7.31	8.57	8.89	10.24	61.59	6.81
0.0	11.19	6.27	8.8	9.31	10.75	76.47	7.33
0.1	10.59	5.21	8.7	8.88	9.8	57.68	6.78
0.0	11.33	6.39	8.82	10.5	11.43	92.66	7.31
0.1	10.75	5.66	8.77	8.87	9.88	59.41	6.79
0.0	106.04	46.57	64.07	110.95	132.63	504.97	43.91
0.1	113.37	53.19	65.44	114.44	139.54	505.85	44.6
0.0	99.18	41.68	62.97	100.78	124.49	516.13	45.36
0.1	101.6	50.97	58.93	98.26	128.96	689.13	43.91

0.0	11.98	8.21	9.04	9.3	11.49	85.41	7.25
0.1	15.09	11.24	8.89	9.39	16.55	70.48	7.04
0.0	11.51	6.86	8.94	9.31	10.82	81.9	7.52
0.1	12.39	8.2	8.8	8.89	12.12	77.09	6.84
0.0	11.78	6.31	9.08	9.8	12.67	79.58	7.24
0.1	13.12	9.11	8.89	9.39	12.78	79.96	6.89
0.0	11.19	7.79	8.35	9.28	10.56	93.43	7.01
0.1	11.54	7.31	8.57	8.89	10.24	61.59	6.81
0.0	11.19	6.27	8.8	9.31	10.75	76.47	7.33
0.1	10.59	5.21	8.7	8.88	9.8	57.68	6.78
0.0	11.33	6.39	8.82	10.5	11.43	92.66	7.31
0.1	10.75	5.66	8.77	8.87	9.88	59.41	6.79
0.0	106.04	46.57	64.07	110.95	132.63	504.97	43.91
0.1	113.37	53.19	65.44	114.44	139.54	505.85	44.6
0.0	99.18	41.68	62.97	100.78	124.49	516.13	45.36
0.1	101.6	50.97	58.93	98.26	128.96	689.13	43.91

A esta matriz **X** la llamaremos matriz de diseño

$\mathbf{x}_1$ será la primera columna de la matriz $\mathbf{X}$

¿Todos nuestros datos son igual de importantes?

La idea de reducción de dimensionalidad es usar un menor número de variables que sean descriptivas de nuestros datos

En lugar de usar 1000 variables, tal vez solo necesitamos 5

Principal Component Analysis

PCA, Análisis de componentes principales

La idea central de PCA es aplicar rotaciones en nuestros datos para maximizar la variabilidad de cada variable.

Principal Component Analysis

PCA, Análisis de componentes principales

Si tenemos $\mathbf{X} = (\mathbf{x}_1,\mathbf{x}_2,\mathbf{x}_3,...,\mathbf{x}_f)$, existe $\mathbf{Y} = (\mathbf{y}_1,\mathbf{y}_2,\mathbf{y}_3,...,\mathbf{y}_f)$ y la matriz $\mathbf{A}$ donde $\mathbf{Y} = \mathbf{AX}$ y para las varianzas de $\mathbf{y}_i$: $\sigma_1 > \sigma_2 > \sigma_3 > ... > \sigma_f$. Además $\mathbf{AA}^T = \mathbf{I}$. Para construir $\mathbf{A}$, primero construiremos la matriz de covarianzas

Matriz de Covarianzas

Sea m_i la media de la columna $\mathbf{x_i}$ definimos la covarianza como

$$S_{ij} = Cov(\mathbf{x_i}, \mathbf{x_j}) = (\mathbf{x_i}^T \mathbf{x_j})/n - m_i m_j$$

donde n es el número de datos de nuestra matriz **X**. S_{ij} es el elemento ij de la matriz de covarianzas **S**. Los elementos diagonales de **S** son las varianzas de $\mathbf{x_i}$

Matriz de Covarianzas

Es posible reescribir **S** en término de sólo **X**, pero para ello debemos introducir el vector **m** de medias

Matriz de Covarianzas

Sea **a** un vector columna de n elementos que tiene en todas sus componentes 1, el vector de medias **m** es:

$\mathbf{m}^T = (\mathbf{a}^T\mathbf{X})/n$

$\mathbf{m} = (\mathbf{X}^T\mathbf{a})/n$

Matriz de Covarianzas

Con esto podemos reescribir **S**

$S_{ij} = Cov(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)/n - m_i m_j$

$\mathbf{S} = (\mathbf{X}^T \mathbf{X})/n - \mathbf{m}\mathbf{m}^T$

Matriz de Covarianzas

Con esto podemos reescribir **S**

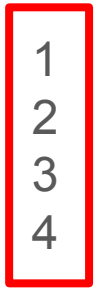
$S_{ij} = Cov(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)/n - m_i m_j$

$\mathbf{S} = (\mathbf{X}^T \mathbf{X})/n - \mathbf{m}\mathbf{m}^T$

1 2 3 4

1
2
3
4

1 2 3 4




1 2 3 4
1
2
3
4



30



30

1
2
3 1 2 3 4
4



30





30

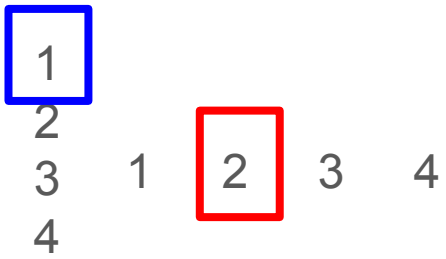
1





30

1 2





30

1 2 3



1 2 3 4

1
2
3
4

30

1
2
3
4

1 2 3 4

	1	2	3	4
1				
2				
3				
4				

	1	2	3	4
1				
2		4	6	8
3		6	9	12
4		8	12	16

Esta operación también se llama producto **diádico** para distinguirla del producto escalar

Matriz de Covarianzas

Con esto podemos reescribir **S**

$S_{ij} = Cov(\mathbf{x}_i, \mathbf{x}_j) = (\mathbf{x}_i^T \mathbf{x}_j)/n - m_i m_j$

$\mathbf{S} = (\mathbf{X}^T \mathbf{X})/n - \mathbf{m}\mathbf{m}^T$

Matriz de Covarianzas

$$\mathbf{S} = (\mathbf{X}^T\mathbf{X})/n - \mathbf{m}\mathbf{m}^T$$

$$\mathbf{m}^T = (\mathbf{a}^T\mathbf{X})/n$$

$$\mathbf{m} = (\mathbf{X}^T\mathbf{a})/n$$

Matriz de Covarianzas

$$\mathbf{S} = (\mathbf{X}^T\mathbf{X})/n - \mathbf{m}\mathbf{m}^T$$

$$\mathbf{m}^T = (\mathbf{a}^T\mathbf{X})/n$$

$$\mathbf{m} = (\mathbf{X}^T\mathbf{a})/n$$

$$\mathbf{S} = (\mathbf{X}^T\mathbf{X})/n - (\mathbf{X}^T\mathbf{a})/n(\mathbf{a}^T\mathbf{X})/n$$

Matriz de Covarianzas

$$\mathbf{S} = (\mathbf{X}^T\mathbf{X})/n - (\mathbf{X}^T\mathbf{a})/n(\mathbf{a}^T\mathbf{X})/n$$

$$\mathbf{S} = [(\mathbf{X}^T\mathbf{X}) - (\mathbf{X}^T\mathbf{a}\mathbf{a}^T\mathbf{X})/n]/n$$

$$\mathbf{S} = [\mathbf{X}^T(\mathbf{I} - \mathbf{a}\mathbf{a}^T/n)\mathbf{X}]/n$$

$$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$$

Matriz de Covarianzas

$$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$$

Matriz de Covarianzas

$$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$$

$$\mathbf{H} = \mathbf{H}^2$$

$$\mathbf{H} = \mathbf{H}^T$$

Matriz de Covarianzas

$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$

$\mathbf{H} = \mathbf{H}^2$ H es un proyector

$\mathbf{H} = \mathbf{H}^T$ H es simétrica

Matriz de Covarianzas

$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$

$\mathbf{H} = \mathbf{H}^2$ H es un proyector

S es simétrica (Lo sabíamos por definición)

Matriz de Covarianzas

$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$

S es definida semipositiva

S es simétrica (Lo sabíamos por definición)

Matriz de Covarianzas

$\mathbf{S} = [\mathbf{X}^T\mathbf{H}\mathbf{X}]/n$

S es definida semipositiva

$\mathbf{w}^T\mathbf{S}\mathbf{w} \geqslant 0$

S es simétrica (Lo sabíamos por definición)

Matriz de Covarianzas

¿Que utilidad tiene la matriz de covarianzas?

Definamos la variable aleatoria y como combinación lineal de las variables $\mathbf{x}_i$. y = $\mathbf{w}^T\mathbf{X}$, **y** son las muestras de nuestra variable y para nuestros datos **X** y **w** los coeficientes de la combinación lineal. La varianza de y es $\mathbf{w}^T\mathbf{S}\mathbf{w}$, con **S** la matriz de covarianza

Matriz de Covarianzas

¿Que utilidad tiene la matriz de covarianzas?

Si la varianza de y es $\mathbf{w}^T\mathbf{S}\mathbf{w}$, con **S** la matriz de covarianza, de aquí también vemos que **S** es definida semipositiva, porque la varianza es mayor o igual que cero.

Principal Component Analysis

Volvemos al problema

Es decir, ahora podemos generar cualquier variable aleatoria y y pedir que esta variable maximice la varianza. De esta manera, encontraremos la dirección en la que hay mayor variabilidad hay de nuestros datos. Esta nueva variable **y** es encontrada como un problema de optimización:

$\max(\mathbf{w}^T\mathbf{S}\mathbf{w})$

Principal Component Analysis

Volvemos al problema

Pero hay un pequeño problema:

$\max(\mathbf{w}^T\mathbf{S}\mathbf{w})$

Principal Component Analysis

Volvemos al problema

Pero hay un pequeño problema:

$\max(\mathbf{w}^T\mathbf{S}\mathbf{w})$

$(10^{20000},0,0,0, \ldots, 0)$

Principal Component Analysis

Volvemos al problema

max($\mathbf{wSw}^T$) sujeto a que el módulo de **w** sea 1

para esto usamos multiplicadores de lagrange

Principal Component Analysis

Volvemos al problema

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

Principal Component Analysis

Hagamos un par de manipulaciones

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

Principal Component Analysis

Hagamos un par de manipulaciones

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

Hagamos un par de manipulaciones

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

¿A nadie de corre un sudor frío por la espalda?

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

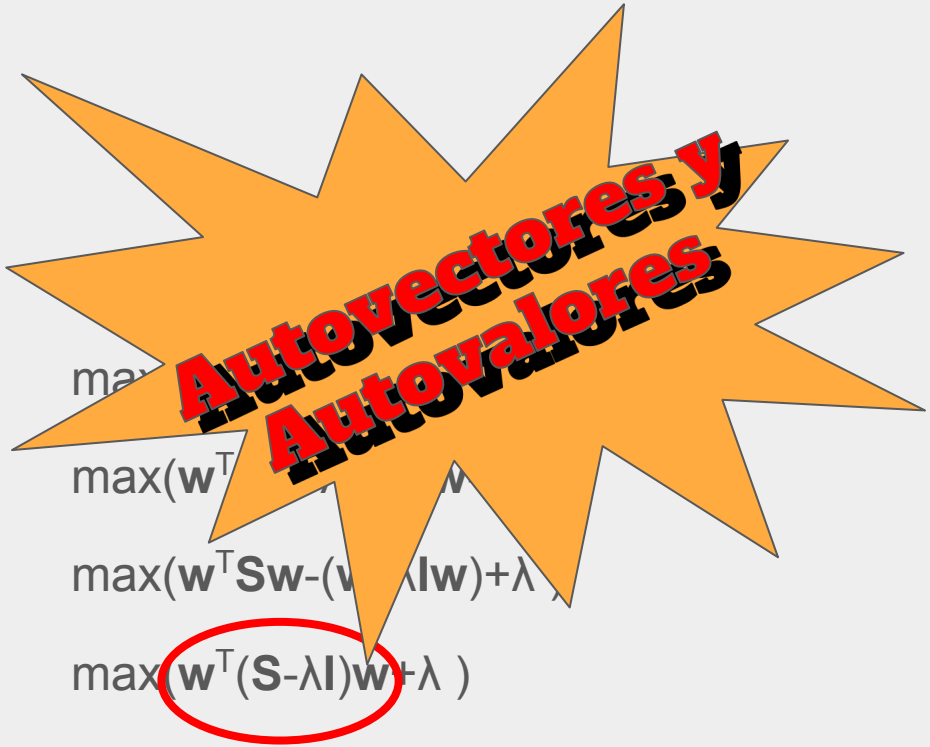
$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

¿A nadie de corre un sudor frío por la espalda?




Always has been
Wait, it's all
Eigenvectors &
Eigenvalues?


Always has been

Principal Component Analysis

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

ENCONTRAMOS EL MÁXIMO

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-\lambda(\mathbf{w}^T\mathbf{I}\mathbf{w}-1))$$

$$\max(\mathbf{w}^T\mathbf{S}\mathbf{w}-(\mathbf{w}^T\lambda\mathbf{I}\mathbf{w})+\lambda)$$

$$\max(\mathbf{w}^T(\mathbf{S}-\lambda\mathbf{I})\mathbf{w}+\lambda)$$

Principal Component Analysis

Estrictamente, este proceso solo encuentra la dirección que maximiza la varianza de nuestros datos (**w**). Pero puede generalizarse para las sucesivas direcciones que maximizan

Para encontrarlas pedimos que las nuevas direcciones sean ortogonales a **w**

Principal Component Analysis

Al pedir ortogonalidad, lo que pedimos es encontrar una matriz de rotaciones que nos lleva de nuestras variables x_i a las variables y_i que cumplen $\sigma_1 > \sigma_2 > \sigma_3 > ... > \sigma_N$.

Principal Component Analysis

PCA, Análisis de componentes principales

Si tenemos $\mathbf{X} = (\mathbf{x}_1,\mathbf{x}_2,\mathbf{x}_3,...,\mathbf{x}_f)$, existe $\mathbf{Y} = (\mathbf{y}_1,\mathbf{y}_2,\mathbf{y}_3,...,\mathbf{y}_f)$ y la matriz $\mathbf{A}$ donde $\mathbf{Y} = \mathbf{AX}$ y para las varianzas de $\mathbf{y}_i$: $\sigma_1 > \sigma_2 > \sigma_3 > ... > \sigma_f$. Además $\mathbf{AA}^T = \mathbf{I}$. Para construir $\mathbf{A}$, primero construiremos la matriz de covarianzas

Principal Component Analysis

La clave es usar las s primeras variables y_i con $s < f$ que nos permitan representar la complejidad de nuestros datos sin perder mucha información. Estas son las s-ésimas componentes principales

Otro punto crucial es centrar nuestro análisis alrededor del vector de medias **m**

Principal Component Analysis

Es decir la transformación total es:

$$\mathbf{Y} = \mathbf{A}(\mathbf{X} - (\mathbf{a}^T\mathbf{X}\mathbf{a}))/n$$

$$\mathbf{Y} = \mathbf{A}(\mathbf{X} - (\mathbf{m}^T\mathbf{a}))/n$$

con **a** un vector columna de n elementos

Principal Component Analysis

Un último de detalle, nada de esto se calcula sobre la matriz S, porque tendría mucha complejidad temporal. En su lugar se recurre a algoritmos iterativos de SVD que operan sobre **X** y tienen mayor velocidad de convergencia. Aunque también existen métodos que permiten calcular SVD de manera exacta

SVD = Singular Value Decomposition