

Ejercicio 1 — Regresión Lineal Multivariable, Ridge y Lasso

Contexto

Trabajas con un dataset de **precios de viviendas**, cuyo objetivo es predecir el **precio de venta** a partir de las características de cada propiedad. El dataset incluye:

- Una **variable respuesta continua**: el precio (o una transformación de este, como el logaritmo del precio).
- Un conjunto de **predictores numéricos continuos** (por ejemplo: superficie, antigüedad, distancia a algún punto de referencia, número de ambientes, puntajes de calidad, etc.).
- Al menos un **predictor binario** (0/1) que indica presencia/ausencia de alguna característica (por ejemplo: garaje, pileta, aire acondicionado, etc.).
- Al menos una **variable categórica con más de dos niveles** (por ejemplo: barrio, tipo de propiedad, zona, condición, etc.).

Antes de empezar, identifica en tu dataset específico: (a) cuál es la variable respuesta (precio u otra transformación), (b) qué columnas son numéricas continuas, (c) qué columna(s) son binarias, y (d) qué columna(s) son categóricas con más de dos niveles. Usa esos nombres reales a lo largo de todo el ejercicio.

Consigna

1. Análisis exploratorio

- Realiza un análisis descriptivo de las variables numéricas y categóricas.
- Examina la distribución de la variable respuesta (precio). ¿Está sesgada? ¿Convendría trabajar con su logaritmo?
- Construye una matriz de correlación entre los predictores numéricos e identifica posibles relaciones fuertes entre ellos.

2. Preparación de datos

- Codifica cada variable categórica con más de dos niveles como variables dummy, usando una categoría de referencia ($k-1$ columnas, no k).
- Justifica por qué no se deben incluir las k dummies completas junto con el intercepto (trampa de la variable dummy).
- Estandariza las variables numéricas (obligatorio antes de aplicar Ridge/Lasso).
- Divide el dataset en entrenamiento y prueba.

3. Regresión lineal multivariable (OLS)

- Ajusta un modelo de regresión lineal múltiple para la variable respuesta usando todos los predictores.
- Reporta e interpreta los coeficientes β (magnitud y signo), incluyendo la

interpretación de las variables dummy respecto a su categoría de referencia.

- Calcula el **VIF** de cada predictor. ¿Hay evidencia de multicolinealidad? ¿Qué variables serían candidatas a eliminar o combinar?
- Evalúa el modelo con **R², R² ajustado, RMSE y MAE** sobre el set de prueba.
- Analiza los residuos: gráfico de residuos vs. valores ajustados y gráfico Q-Q. ¿Se cumplen los supuestos de Gauss-Markov?

4. Regresión Ridge

- Ajusta un modelo Ridge sobre los mismos predictores.
- Realiza una búsqueda de λ (por ejemplo, con validación cruzada de 5 o 10 folds) y grafica el **camino de regularización** (coeficientes vs. λ).
- Compara los coeficientes de Ridge contra los de OLS. ¿Qué ocurre con los predictores correlacionados?

5. Regresión Lasso

- Ajusta un modelo Lasso sobre los mismos predictores, también seleccionando λ por validación cruzada.
- Identifica qué coeficientes fueron llevados exactamente a cero. ¿Qué variables "sobrevivieron"? Interpreta el resultado como selección de variables.

6. Comparación final

- Construye una tabla comparativa (OLS vs. Ridge vs. Lasso) con: RMSE en test, número de predictores efectivos, e interpretabilidad.
- Con base en el trade-off sesgo-varianza, justifica cuál modelo recomendarías para este caso de negocio y por qué.

Entregables

Notebook o script reproducible, informe breve (máx. 2 páginas) con las conclusiones y la tabla comparativa final.

Ejercicio 2 — Regresión Logística Multivariable

Contexto

Trabajas con un dataset que contiene información de clientes y una **variable respuesta binaria** que indica si ocurrió o no un evento de interés (default.).

El dataset incluye:

- Una **variable respuesta binaria** (0 = no ocurre el evento, 1 = ocurre el evento).
- Un conjunto de **predictores numéricos continuos** (por ejemplo: edad, ingreso, monto, antigüedad, puntaje, etc.).
- Al menos un **predictor binario** (0/1) que indica la presencia/ausencia de una condición.
- Al menos una **variable categórica con más de dos niveles** (por ejemplo: tipo de producto, categoría, región, nivel educativo, etc.).

Antes de empezar, identifica en tu dataset específico: (a) cuál es la variable respuesta, (b) qué columnas son numéricas continuas, (c) qué columna(s) son binarias, y (d) qué columna(s) son categóricas con más de dos niveles. Usa esos nombres reales a lo largo de todo el ejercicio.

Consigna

1. Análisis exploratorio

- Examina el balance de clases de la variable respuesta. ¿El dataset está desbalanceado? ¿Qué implicancias tiene esto para las métricas que usarás más adelante?
- Explora visualmente cómo varían los predictores numéricos y categóricos entre los casos donde el evento ocurre y donde no ocurre.
- Construye una matriz de correlación entre los predictores numéricos e identifica relaciones fuertes.

2. Preparación de datos

- Codifica cada variable categórica con más de dos niveles como variables dummy, usando una categoría de referencia ($k-1$ columnas, no k).
- Explica por qué no se deben incluir las k dummies completas junto con el intercepto (trampa de la variable dummy).
- Divide el dataset en entrenamiento y prueba (por ejemplo, 70/30), manteniendo la proporción de clases (muestreo estratificado).

3. Ajuste del modelo

- Ajusta un modelo de regresión logística multivariable para la variable respuesta usando todos los predictores.
- Explica por qué **no es apropiado usar OLS** para esta variable respuesta.
- Indica si el modelo se resolvió por descenso de gradiente o Newton-Raphson (según la librería utilizada) y qué función de costo se está minimizando.

4. Interpretación de coeficientes

- Calcula e interpreta los **odds ratios** ($\exp(\beta)$) de cada predictor.
- Identifica qué variables aumentan y cuáles disminuyen las probabilidades del evento, y en qué magnitud relativa.
- Para las variables dummy, interpreta cada coeficiente en relación con la categoría de referencia elegida.

5. Frontera de decisión y umbral

- Con el umbral por defecto (0.5), genera las predicciones de clase sobre el set de prueba.
- Discute qué ocurriría con las predicciones si se baja o sube el umbral de clasificación (¿qué se gana y qué se pierde en términos del problema de negocio o aplicación concreta que elegiste?).

6. Evaluación del modelo

- Construye la **matriz de confusión** sobre el set de prueba.

- Calcula **Accuracy, Precision, Recall y F1-score**.
- Grafica la **curva ROC** y calcula el **AUC**.
- Grafica la **curva Precision-Recall** y justifica por qué es especialmente relevante dado el balance de clases evaluado en el punto 1.
- Calcula el **log-loss** del modelo y explica qué mide que las otras métricas no capturan.

7. Conclusión

- Con base en el objetivo específico de tu problema (por ejemplo, minimizar falsos negativos o falsos positivos, según el costo de cada tipo de error en tu contexto), recomienda qué métrica(s) debería priorizarse y qué umbral de clasificación usarías.

Entregables

notebook o script reproducible, tabla resumen de métricas, y un párrafo de recomendación orientada al contexto de aplicación elegido.