TRABAJO PRÁCTICO · INTELIGENCIA ARTIFICIAL 2

Generando caras de Los Simpson



Un autoencoder variacional que comprime cada cara a 128 números y la vuelve a dibujar

LA HISTORIA

Tres actos



Acto	Qué pasa	Con qué nos quedamos
1	El caso base: el autoencoder	**Reconstruye bien, pero no puede generar**
2	La mejora: la divergencia KL	**Codificar una nube, no un punto**
3	Todos los datos juntos	**«Simplificar» es una dirección del latente**

LA PREGUNTA DE FONDO

¿Cómo se consigue que una red invente caras nuevas sin que nadie le diga nunca qué personaje es cada una?



EL DATASET

9.877 caras, cero etiquetas



9.877 imágenes

200×200 px · RGB · PNG · 400 MB

Kaggle — «Simpsons Faces», de kostastokis

> **SIN ETIQUETAS**
>
> No sabemos qué personaje es cada cara. En un autoencoder no hace falta: la respuesta correcta para cada imagen es esa misma imagen.

EL DATASET

De 12.288 números a 128



200×200 → 64×64

Interpolación LANCZOS. Píxeles escalados a [0, 1].

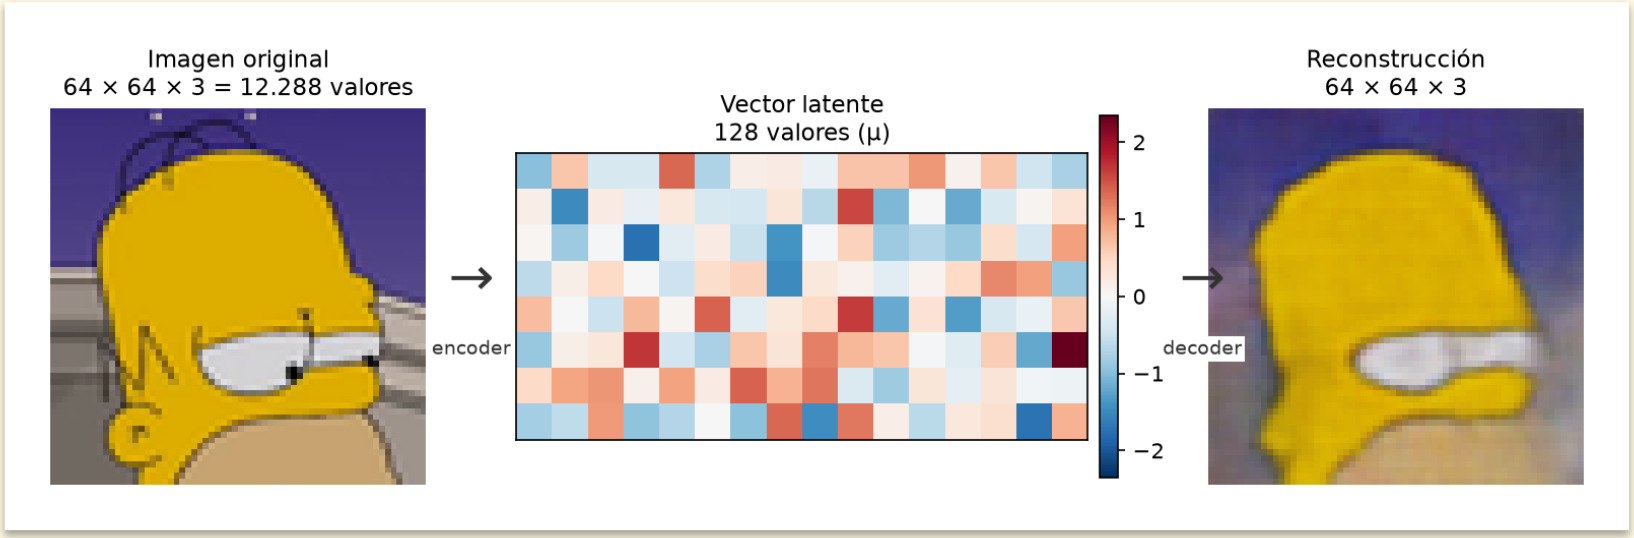
Split 95 / 5

9.383 de entrenamiento y 494 de validación.

EL NÚMERO QUE IMPORTA

Cada imagen son 12.288 valores (64 × 64 × 3) y los comprimimos a 128: 96 veces menos. Casi cualquier combinación de esos 12.288 valores es ruido — las caras ocupan un rincón muy chico del espacio.

Encoder, espacio latente, decoder



Encoder

Comprime la imagen a un vector chico.

Latente

Donde viven los códigos z: 128 números.

Decoder

Descomprime el vector a una imagen.

ACTO 1 · EL CASO BASE

El objetivo: reconstruir lo mejor posible

$$\mathrm{BCE}(x, \hat{x}) = -\Sigma\,[\, x \cdot \log(\hat{x}) + (1 - x) \cdot \log(1 - \hat{x})\,]$$

Sigmoide + [0, 1]

La salida del decoder y los píxeles reales viven en el mismo rango: se comparan como probabilidades.

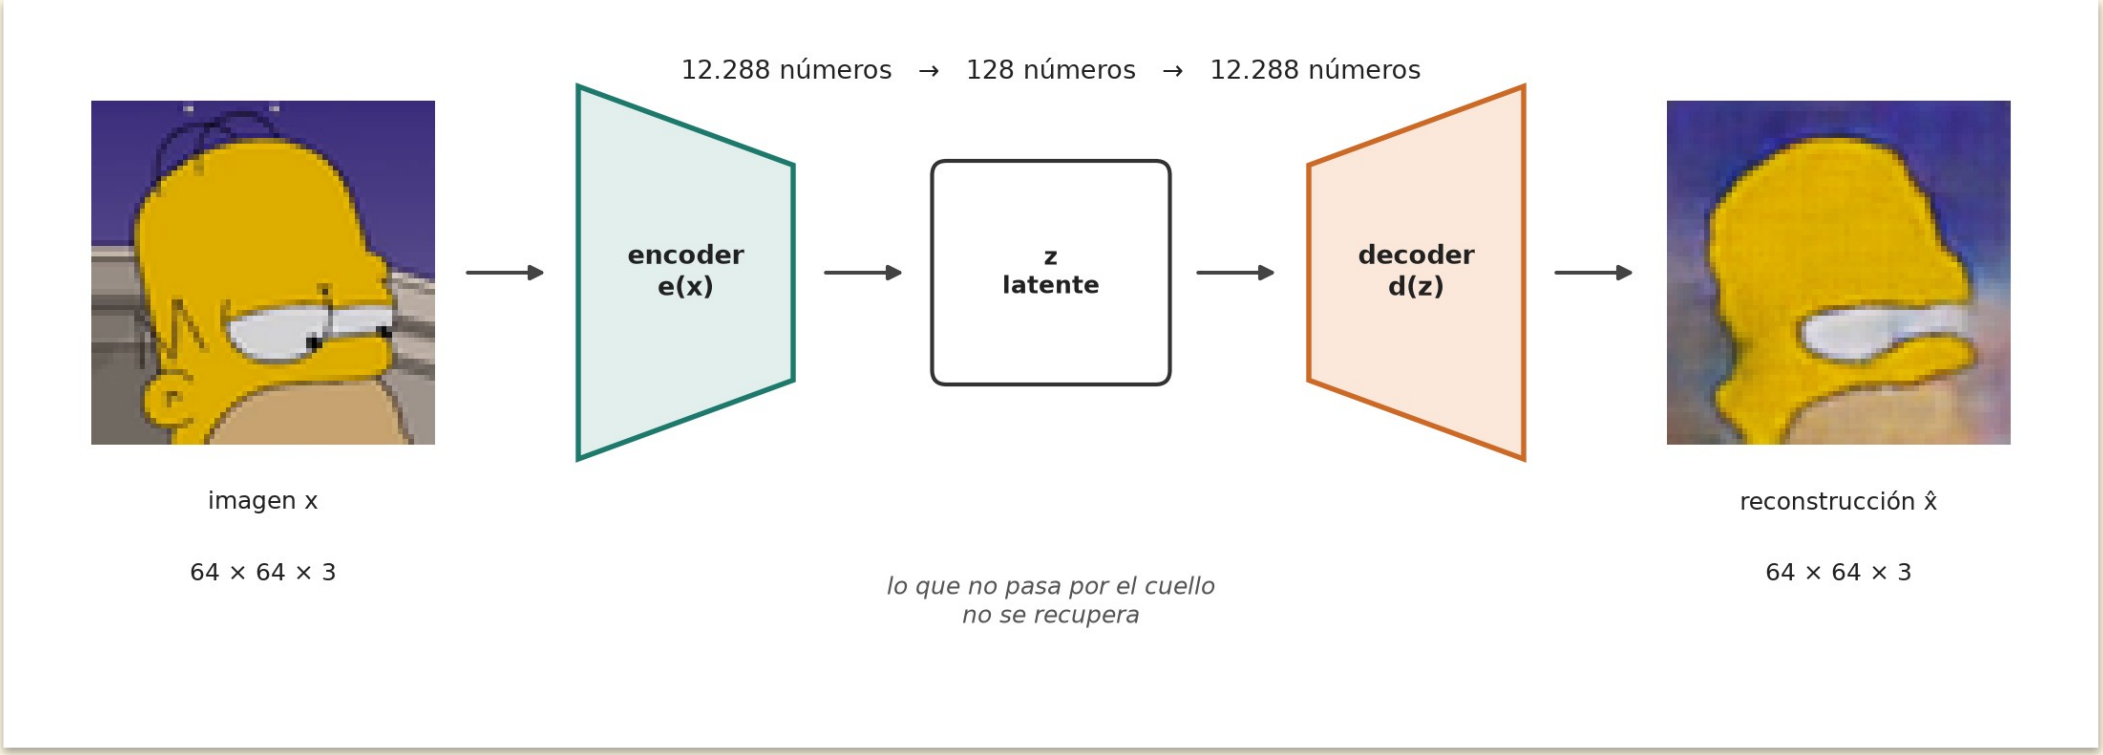
Suma sobre 12.288 valores

Por eso las pérdidas se miden en miles de nats por imagen.

INTUICIÓN

El dato es su propia etiqueta. No hace falta etiquetar nada: la respuesta correcta para cada cara es esa misma cara.

Encoder y decoder espejados



4 convoluciones con stride 2: 64 → 32 → 16 → 8 → 4. El decoder, al revés. **2.434.243 parámetros.**

ACTO 1 · EL CASO BASE

Y aprende



Sobrevive

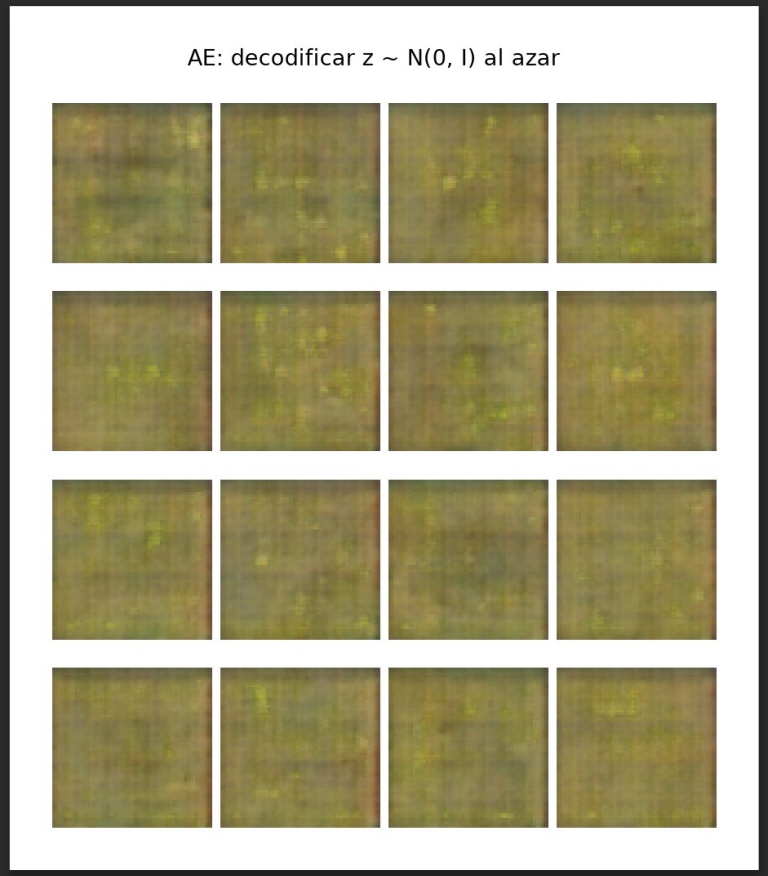
Forma de la cabeza, peinado, colores, pose, fondo.

Se pierde

El detalle fino: las líneas negras del contorno, los bordes nítidos.

ACTO 1 · EL CASO BASE

La idea tentadora

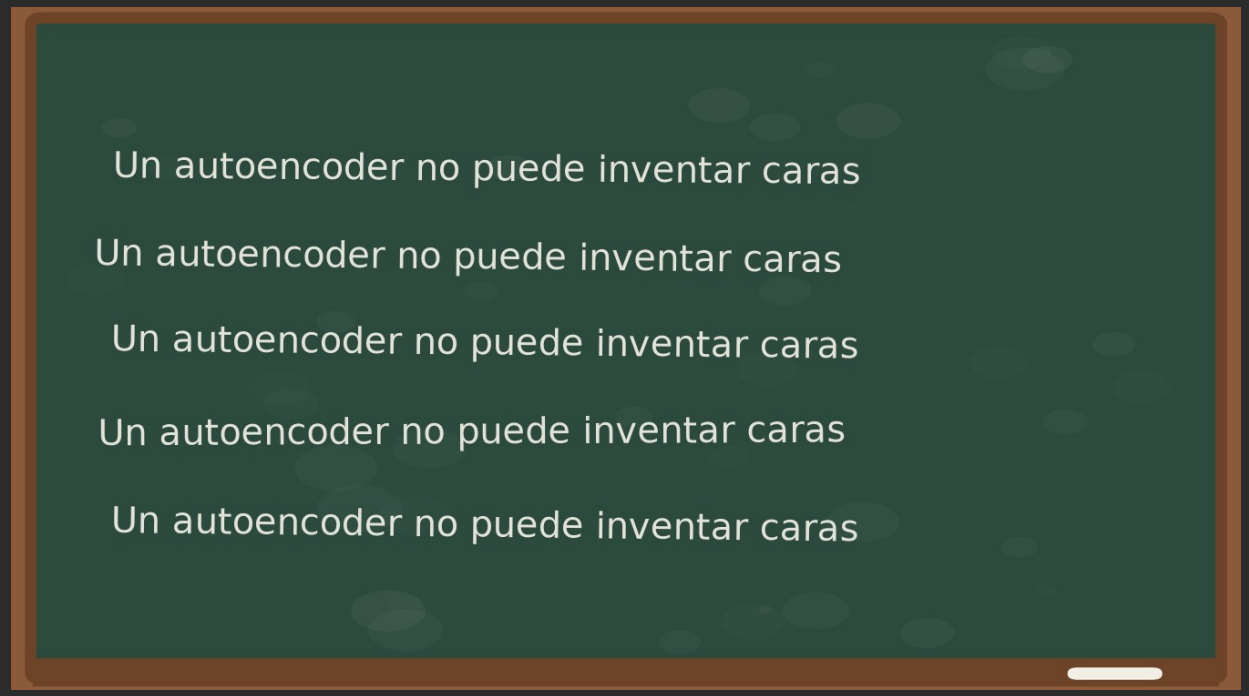


Ya tenemos un decoder, ¿no?

Sorteamos 16 vectores de N(0, I) y los decodificamos. No salen caras: sale **la misma mancha dieciséis veces**.

Que siempre devuelva lo mismo es la pista de dónde cayeron esos vectores.

No anda.

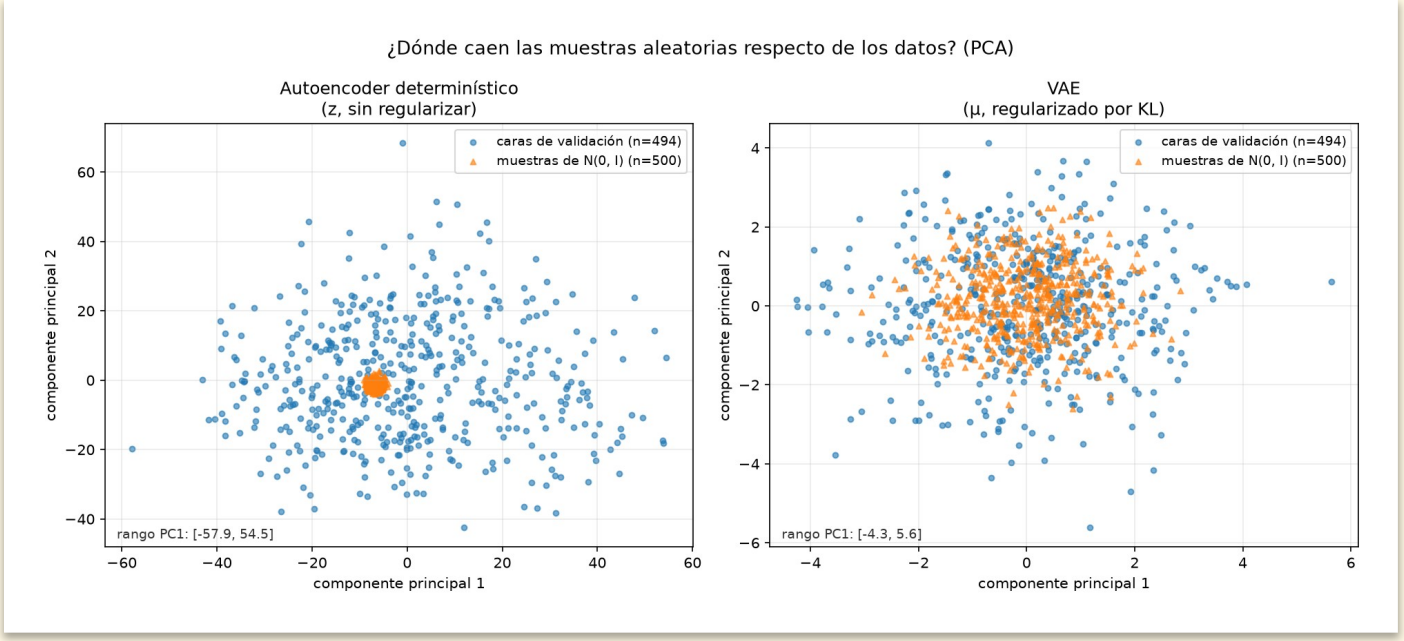


ACTO 1 · EL CASO BASE

La moraleja del acto

Comprime y descomprime. Reconstruye bien. Y no puede inventar nada.

Por qué falla: islas y huecos

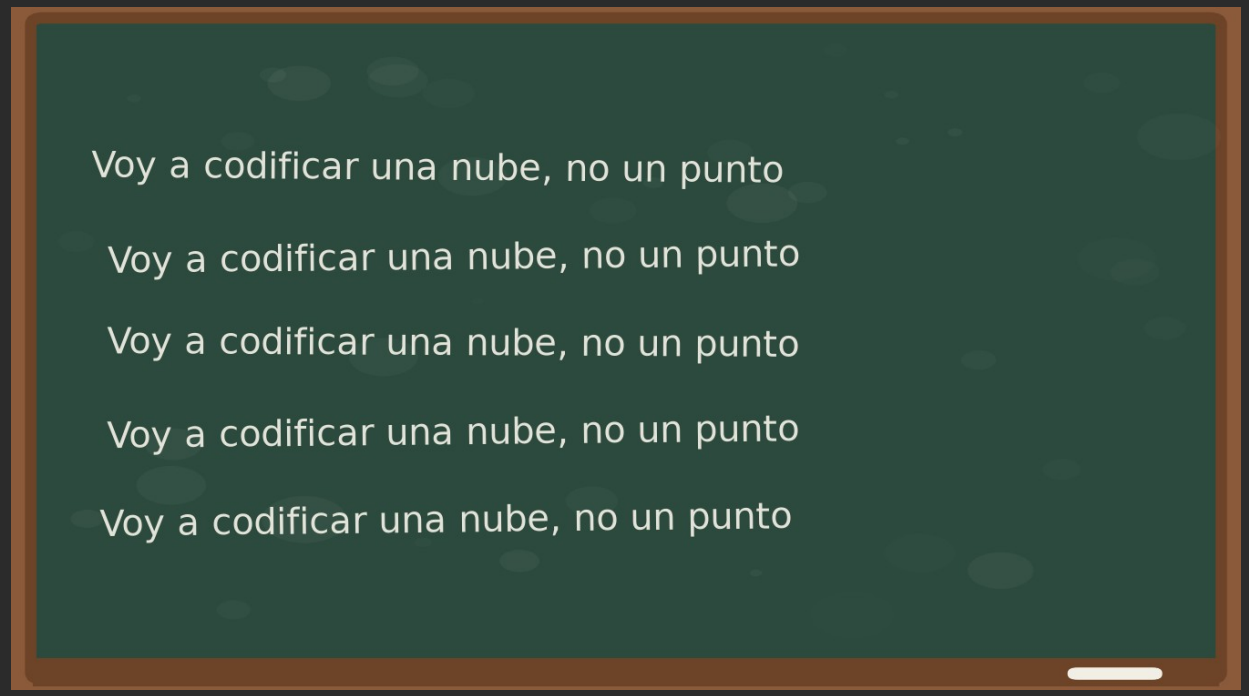


CONTINUIDAD

Dos puntos cercanos deberían dar imágenes parecidas.

COMPLETITUD

Cualquier punto razonable debería dar algo con sentido.

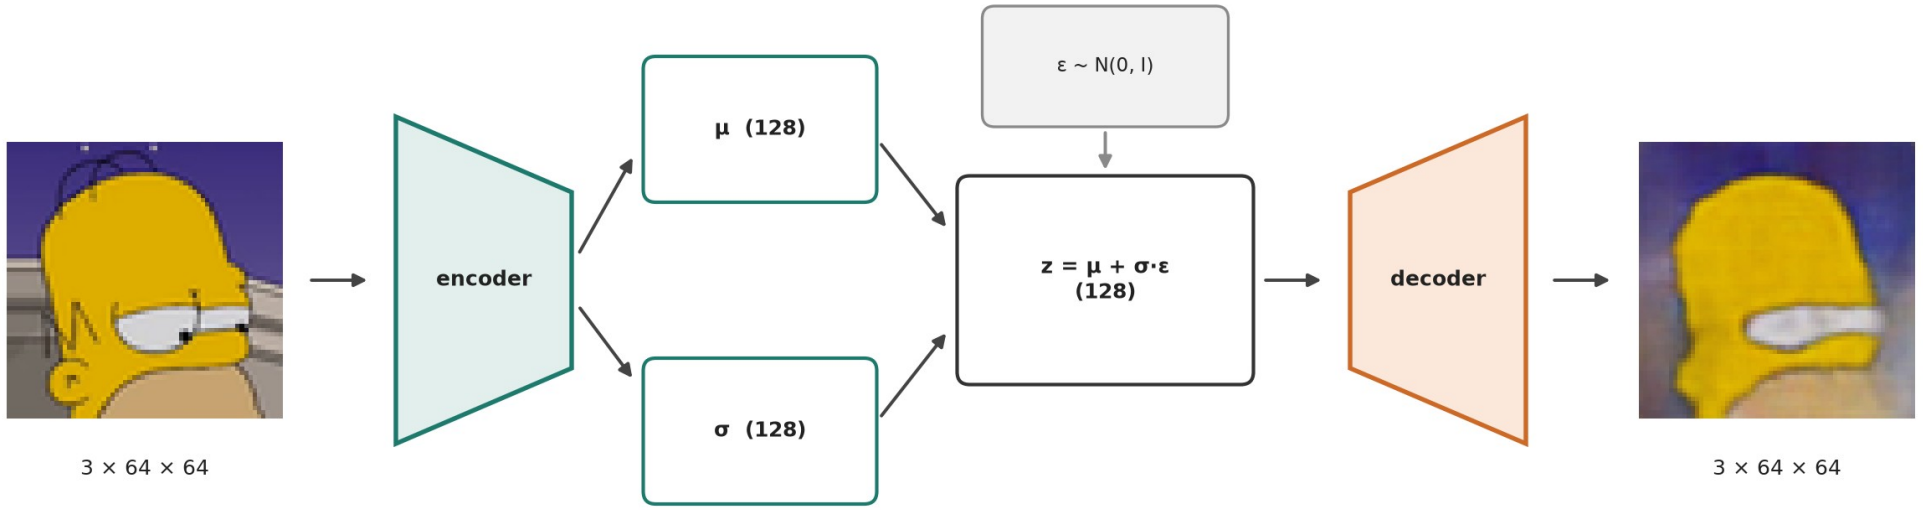


ACTO 2 · LA MEJORA

La divergencia KL

Si queremos un espacio sin huecos, tenemos que pedirlo.

Codificar una nube, no un punto



$$q(z \mid x) = N(\mu(x), \sigma^2(x))$$

Dos cabezas y un sorteo en el medio: solo **524.416 parámetros más**.

ACTO 2 · LA MEJORA

El resorte: la divergencia KL

$$KL = \tfrac{1}{2} \sum_j \left(\mu_j^2 + \sigma_j^2 - \log \sigma_j^2 - 1 \right)$$

μ^2 · resorte al origen

Impide separar las nubes. Sin esto, la red las manda lejos unas de otras y vuelven las islas.

$\sigma^2 - \log \sigma^2 - 1$ · ni chica ni grande

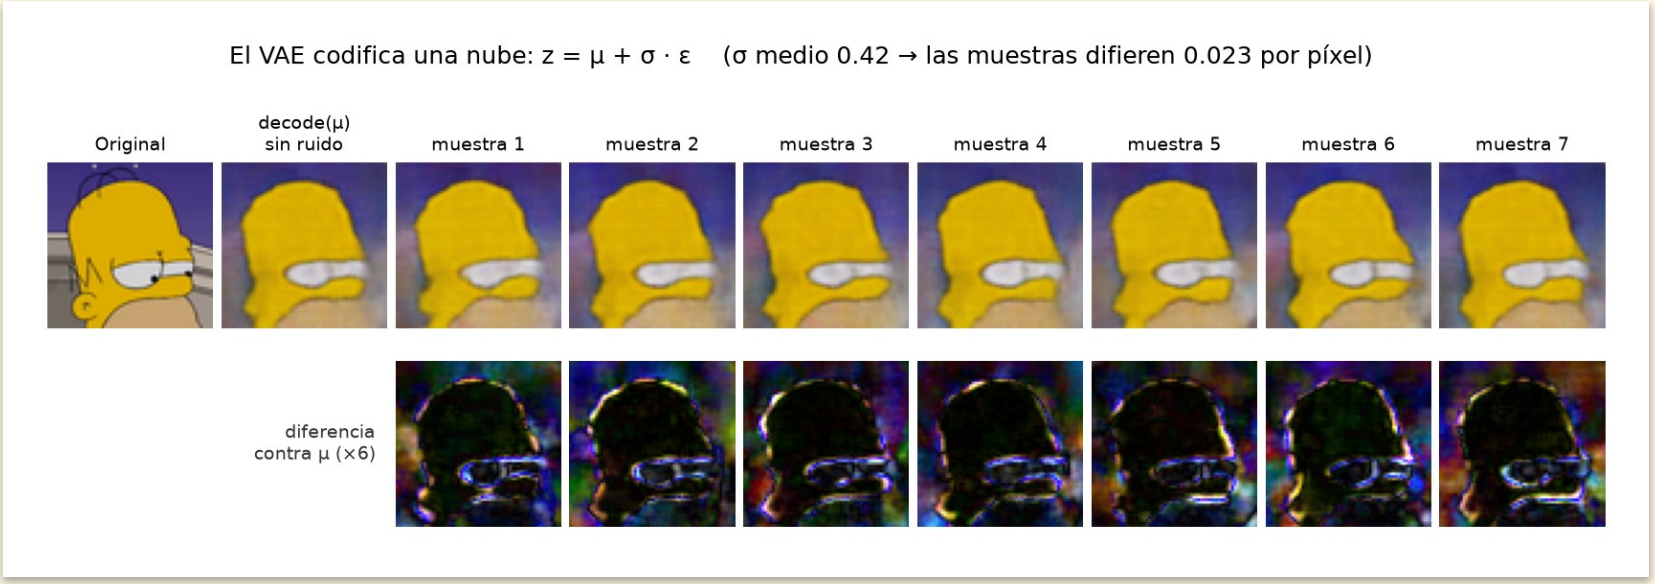
Vale 0 en $\sigma = 1$ y castiga los dos extremos. Impide achicar las nubes hasta volver a un punto.

PÉRDIDA TOTAL

$BCE(x, \hat{x}) + KL(N(\mu, \sigma^2) \,\|\, N(0, I))$. La reconstrucción quiere nubes chicas y separadas; la KL las quiere estándar y encimadas. El VAE queda en el medio.

ACTO 2 · LA MEJORA

La nube de una cara



DÓNDE VARÍA

La nube es angosta (σ medio 0,38), así que las muestras parecen iguales. La fila de abajo amplifica la diferencia ×6: toda la variación está en los contornos y el fondo, no en el relleno.

ACTO 2 · LA MEJORA

¿Y si agrandamos la nube?



$$z = \mu + k \cdot \sigma \cdot \varepsilon$$

k = 0 · la reconstrucción exacta

k = 1 · el tamaño que aprendió

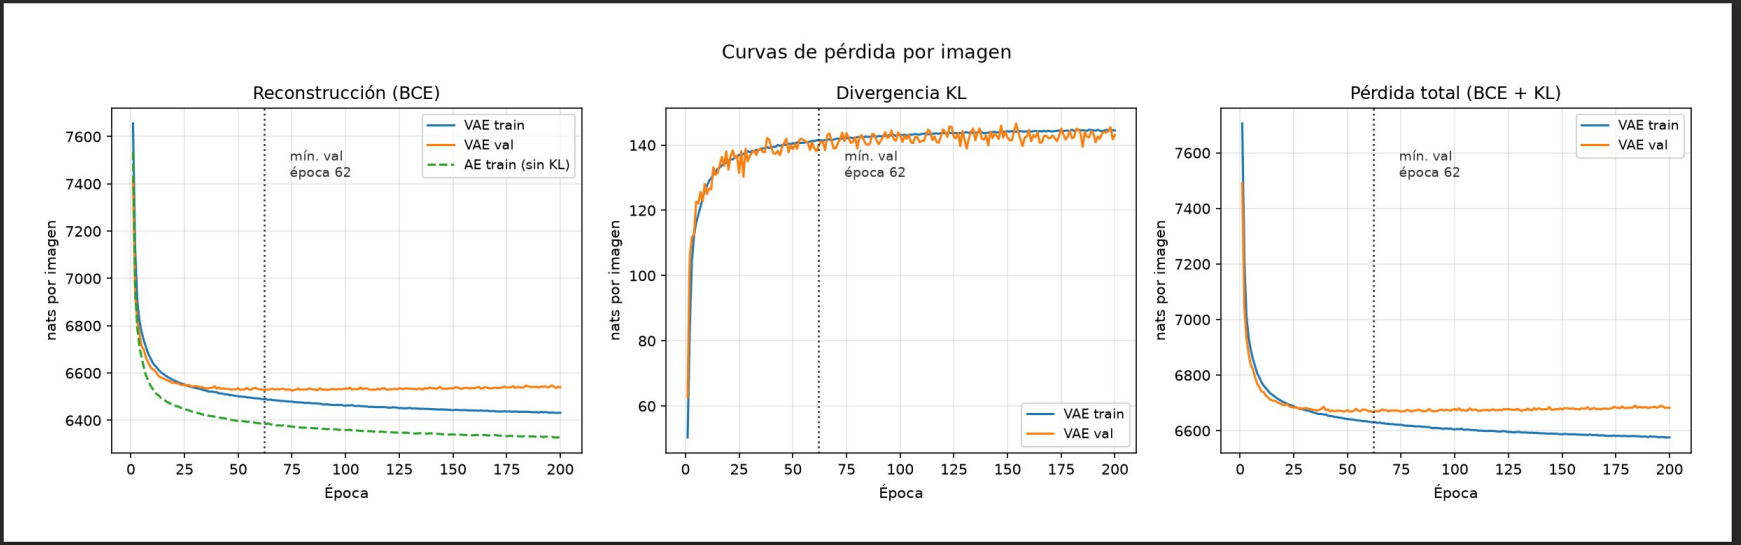
k = 3 · todavía la misma cara

k = 6 · recién acá se desarma

> Cada fila lleva la diferencia medida por píxel: crece siempre, aunque el ojo no la registre hasta k alto.

ACTO 2 · LA MEJORA

Esta vez la pérdida sí informa



POR IMAGEN, 200 ÉPOCAS

6.576

Mínimo de validación en la época 62: 6.668,29 nats.

KL estable en ~**144 nats**: no hubo colapso.

101 de 128 dimensiones latentes llevan información.

ACTO 2 · LA MEJORA

Reconstrucción: época 30 contra 200



Validación	nats
Época 30	6.681,14
Época 200	6.682,84
Mejor (ép. 62)	**6.668,29**

La métrica se amesetó, pero los detalles finos sí mejoran: la pérdida promedia 12.288 valores y no registra una mejora de borde.

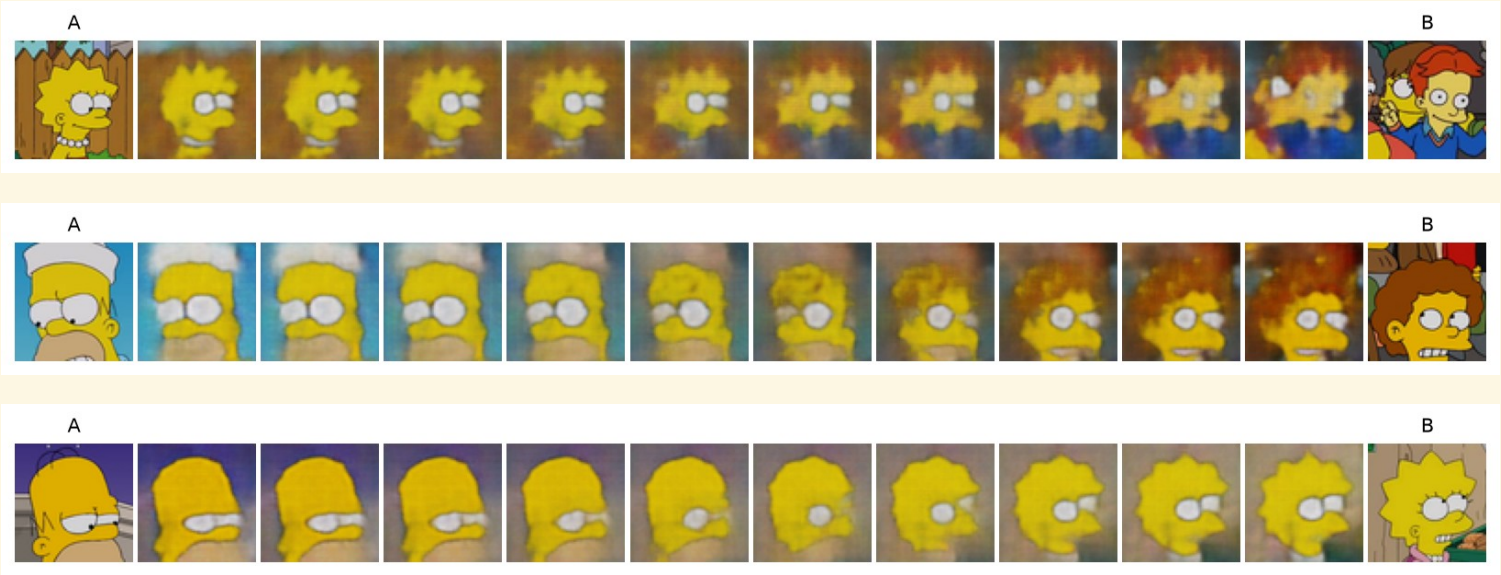
El pago: caras que no existen



Mismos z, misma arquitectura, mismos datos. **La diferencia es el término KL.**

ACTO 2 · LA MEJORA

Caminar entre dos caras



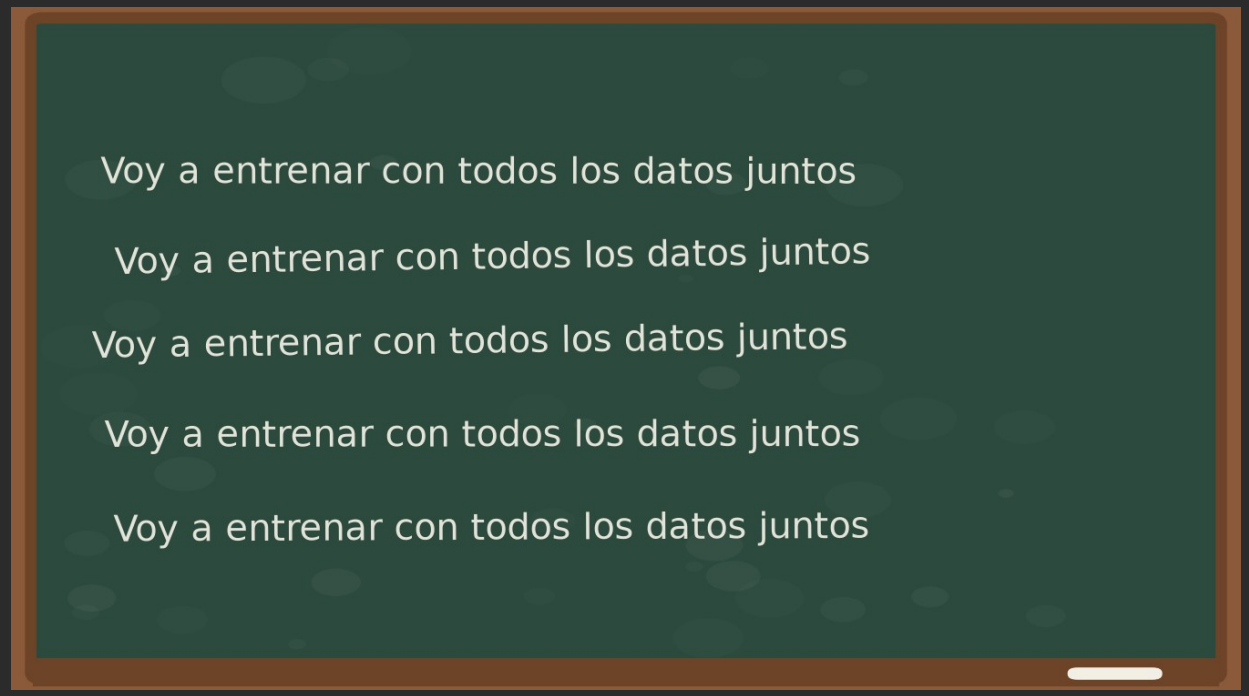
$$z = (1-t)\cdot\mu A + t\cdot\mu B$$

TRANSICIÓN GRADUAL

Los diez pasos intermedios son caras válidas: no hay saltos ni zonas rotas.

POR DISEÑO

Es la continuidad del acto 1. En el autoencoder el camino podía cruzar un hueco.



ACTO 3 · TODOS LOS DATOS

Un solo modelo, los dos estilos

El dataset trae cada cara dos veces. ¿Qué pasa si las mezclamos?

ACTO 3 · TODOS LOS DATOS

Cada cara viene en dos versiones



cropped

El fotograma real: sombreados, texturas, fondos. ~9.500 colores únicos por imagen.

simplified

La misma cara con colores planos. 3 colores únicos por imagen.

LA PREGUNTA

¿Qué hace el modelo cuando tiene que acomodar los dos estilos en el mismo latente de 128 dimensiones?

ACTO 3 · TODOS LOS DATOS

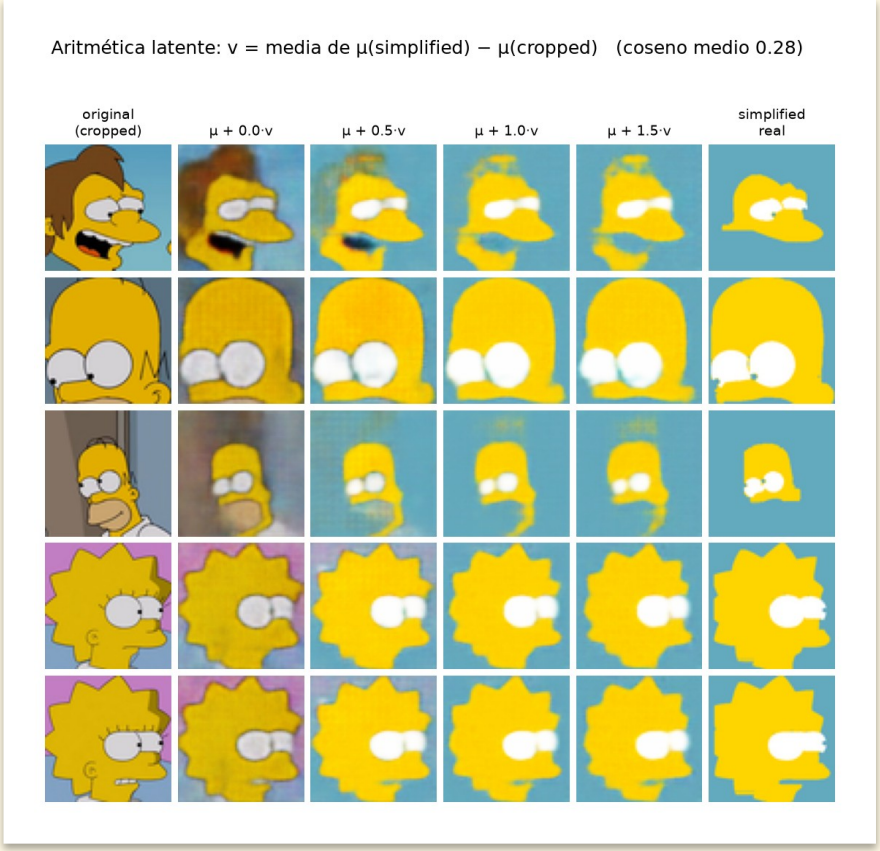
Un VAE con 19.754 imágenes

	solo cropped	solo simplified	los dos juntos
Imágenes	9.877	9.877	**19.754**
Pérdida total (train)	6.576,28	5.559,30	**6.090,26**
Divergencia KL	144,49	106,90	**129,07**
Brecha val − train	106,56	18,06	**75,69**
Tiempo	10,6 min	7,7 min	**17,9 min**

Queda entre los dos, como era esperable. Lo interesante no está en la pérdida: está en cómo organizó el espacio latente.

ACTO 3 · TODOS LOS DATOS

«Simplificar» es una dirección



v = media(μ_simp − μ_crop)

CONSISTENTE

El 100 % de los 1.500 pares apunta para el mismo lado (coseno medio 0,28).

Y GENERALIZA

Estas caras no entraron en el cálculo de v. El modelo nunca supo que las imágenes venían en pares.

ACTO 3 · TODOS LOS DATOS

Caminar de un estilo al otro

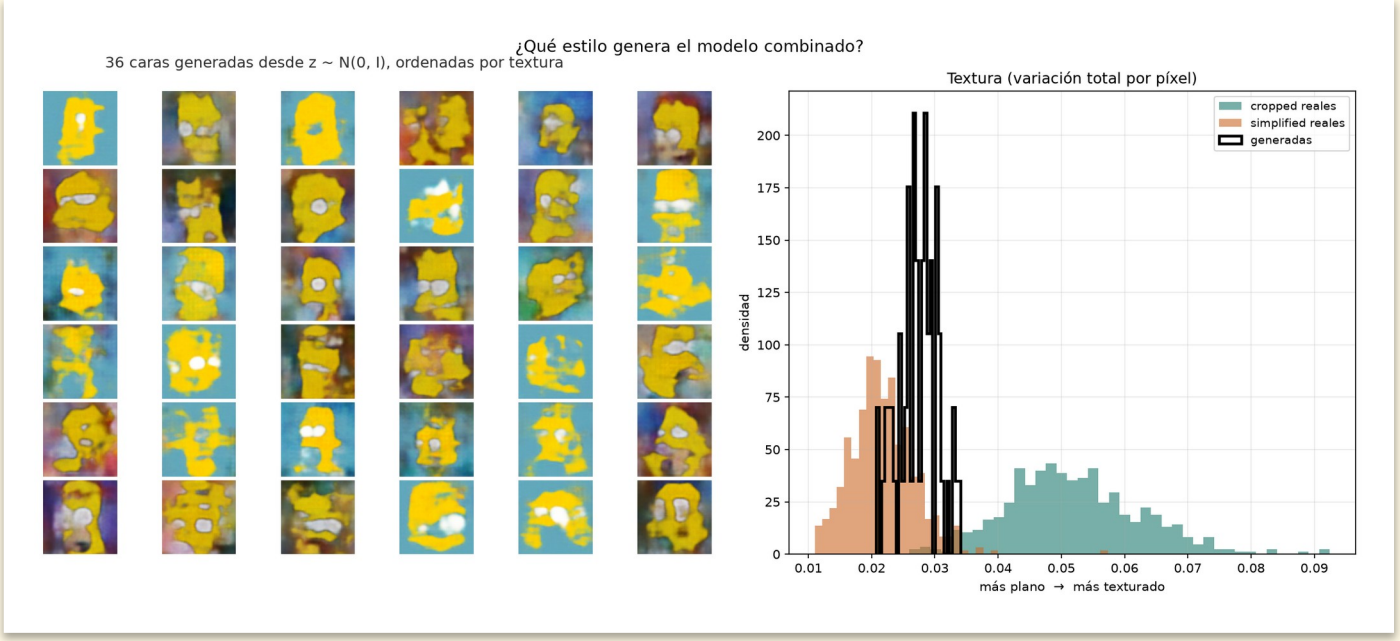


IDENTIDAD Y ESTILO, SEPARABLES

La transición es suave y la cara es siempre la misma, en la misma pose. El modelo puede mover el estilo dejando quieta la identidad.

ACTO 3 · TODOS LOS DATOS

¿Y qué estilo inventa?



46 % / 54 %

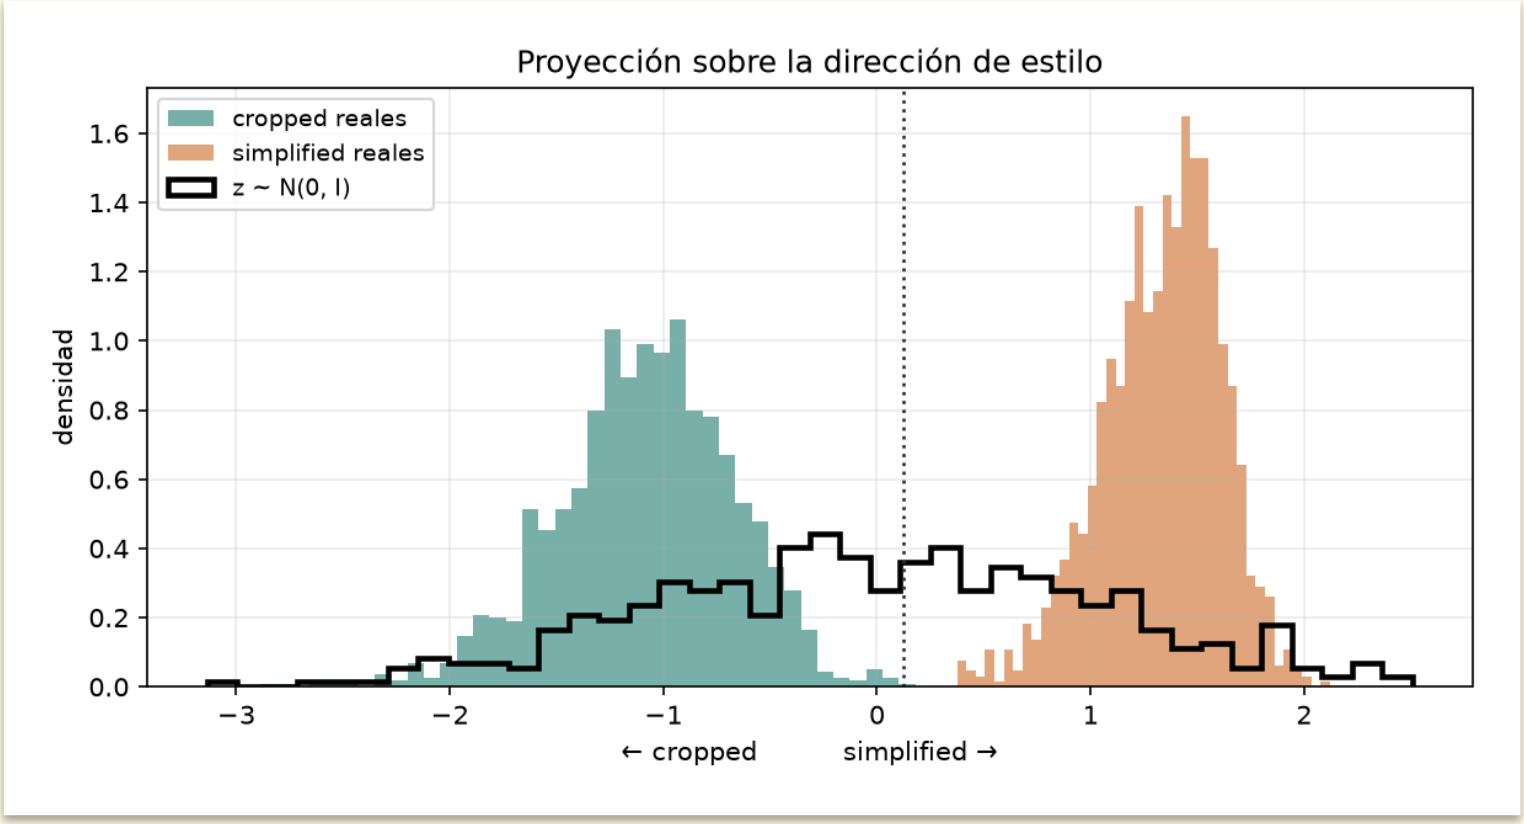
Reparto parejo entre los dos estilos, medido en el espacio latente.

Y también híbridos

En el medio aparecen caras que no existen en ninguna de las dos carpetas.

ACTO 3 · TODOS LOS DATOS

Cómo medimos en qué estilo dibuja



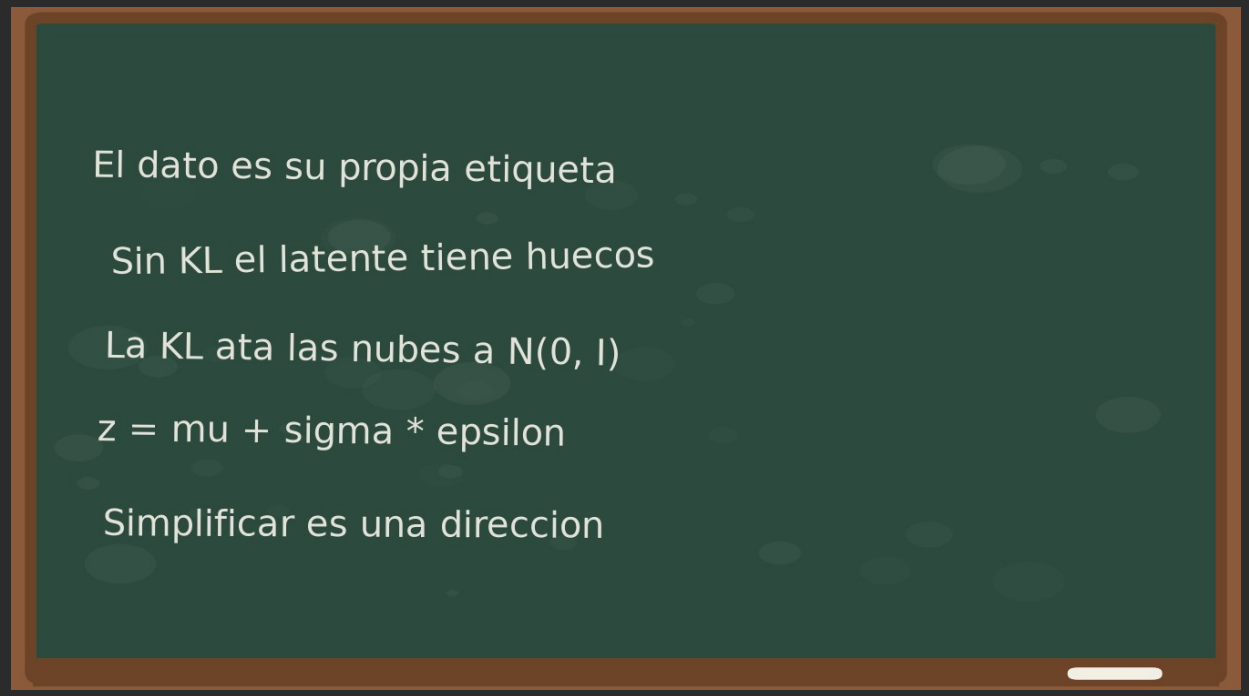
1. Normalizamos la dirección v.
2. Proyectamos los μ reales: cropped -1,09, simplified 1,33.
3. Proyectamos los z del prior y vemos de qué lado caen.

46 % / 54 %

Reparto entre los dos estilos.

LO QUE NO SIRVE

La textura por píxel: el desenfoque la baja igual que la simplificación.



CIERRE

Lo que aprendimos

Todo el trabajo, escrito en el pizarrón.

CIERRE

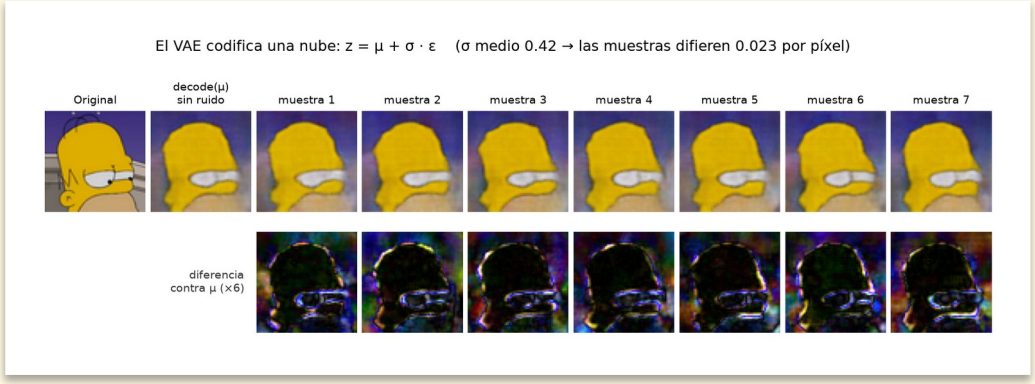
Por qué sale borroso

POR QUÉ ES BORROSO

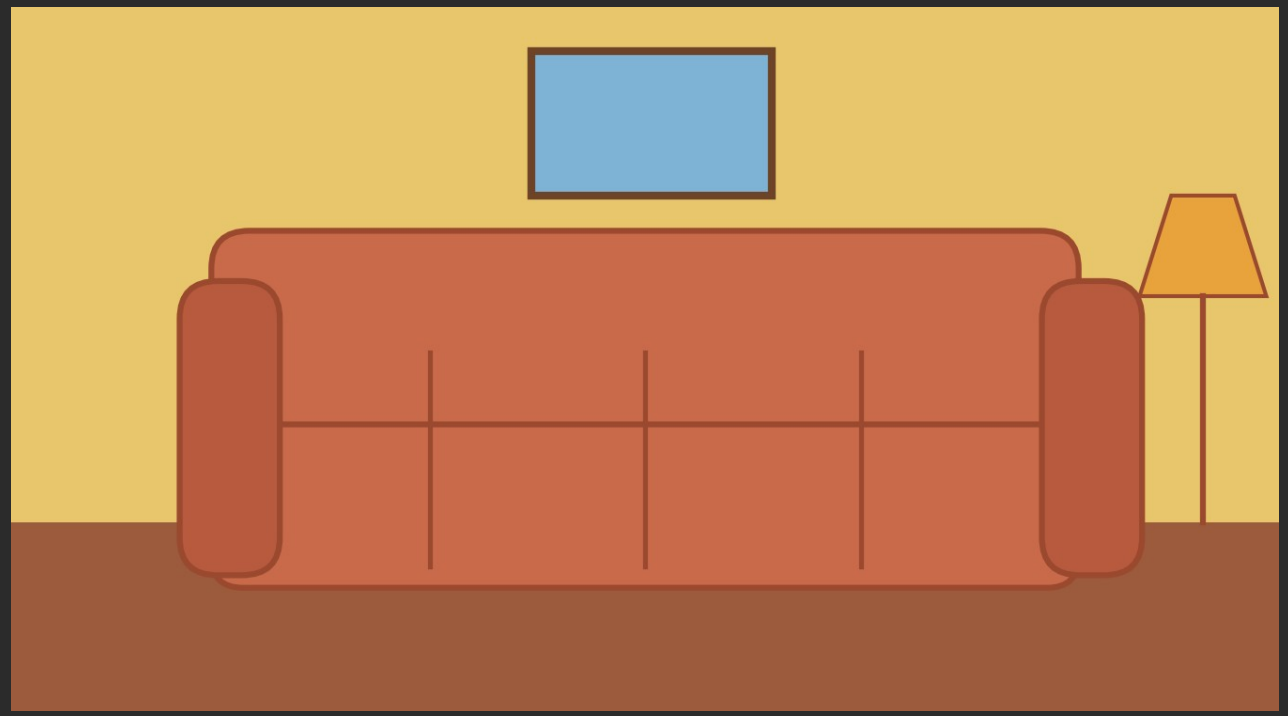
La BCE premia el promedio de las posiciones posibles de cada borde. El promedio de muchas caras es una cara borrosa. No es falta de entrenamiento.

QUÉ HACE DISTINTO UNA GAN

El discriminador castiga lo que no parece real, y una cara promedio no lo parece. Más nítido, a cambio de inestabilidad y mode collapse.



La prueba: la variación del modelo está toda en los contornos, que es justo donde **no sabe dónde cae el borde**.



GRACIAS

¿Preguntas?

Todo el código, los checkpoints y las figuras están en el repositorio del trabajo.

Los tres modelos se entrenan de cero en menos de 40 minutos de GPU.

